

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



KHO DỮ LIỆU VÀ HỆ HỖ TRỢ QUYẾT ĐỊNH (CO5113)

Báo cáo Coursework – Chủ đề: Customer Churn

“Dataset Analysis”

Hiểu khách hàng của CompanyX qua kho dữ liệu

GVHD: ...

Nhóm: ...

SV thực hiện: Lương Bảo Thiên - MSSV

Phân phụ trách: Mục 3 – Dataset Analysis

TP. HỒ CHÍ MINH, THÁNG 09/2026



Mục lục

1	Kho dữ liệu CompanyX có gì?	1
1.1	Nguồn gốc và quy mô	1
1.2	Sáu nhóm bảng theo bộ phận nghiệp vụ	2
1.3	Các bảng quan trọng và ý nghĩa của chúng	3
1.4	Những bảng nào thực sự cần cho chủ đề?	5
1.5	Dữ liệu này đáng tin đến đâu?	6
2	Chủ đề khách hàng rời bỏ trên kho dữ liệu này	10
3	Khách hàng của chúng ta là ai?	10
3.1	Hai nhóm khách hàng rất khác nhau	10
3.2	Chân dung khách cá nhân	11
3.3	Chân dung đại lý	11
3.4	Khách hàng ở đâu?	11
4	Khách hàng thích mua sản phẩm gì?	12
4.1	Doanh thu và độ phủ khách hàng theo danh mục sản phẩm	12
4.2	Khách cá nhân và đại lý mua những thứ khác nhau	13
4.3	Khách có mua nhiều loại hàng khác nhau không?	13
5	Khách hàng mua như thế nào?	13
5.1	Mua bao nhiêu lần?	13
5.2	Mua vào lúc nào?	14
5.3	Vì sao họ mua?	15
6	Ai đang rời bỏ và dấu hiệu nào đi kèm?	15
6.1	Thế nào là “rời bỏ” đối với doanh nghiệp bán lẻ?	15
6.2	Đại lý rời bỏ nhiều gấp đôi khách cá nhân	17
6.3	Khách tại Úc có tỷ lệ rời bỏ quan sát thấp nhất	17
6.4	Số lần mua trước mốc và tỷ lệ rời bỏ	17
6.5	Loại hàng đã mua trước mốc và tỷ lệ rời bỏ	19
6.6	Chênh lệch tỷ lệ rời bỏ theo đặc điểm nhân khẩu học	20
6.7	Tổng hợp: dấu hiệu nào đi kèm với việc rời bỏ?	21
7	Giới hạn của dữ liệu và đầu vào cho giai đoạn tiếp theo	22
7.1	Dữ liệu có đủ điều kiện để nghiên cứu churn không?	22
7.2	Những giới hạn cần ghi nhận	22
7.3	Đầu vào cho các phần tiếp theo	23
8	Kết luận	24
A	Môi trường thực thi và cách tái lập kết quả	25
B	Truy vấn kiểm chứng và kết quả thực thi	27



B.1	Kho dữ liệu có gì bên trong — xem trực tiếp bằng <code>sqlcmd</code>	27
B.2	V01 — Doanh thu và tính nhất quán giữa hai cấp dữ liệu	34
B.3	V02 — Chất lượng dữ liệu	35
B.4	V03 — Kênh bán và mức tập trung doanh thu	36
B.5	V04 — Gắn nhãn rời bỏ	37
B.6	V05 — Số lần mua trước mốc	38
B.7	V06 — Danh mục sản phẩm đã mua trước mốc	40
B.8	V07 — Nhân khẩu học và tỷ lệ rời bỏ	41
B.9	V08–V09 — Lý do mua, khuyến mãi và phân bố thời gian	42
B.10	V10–V12 — Cấu trúc kho, nhịp mua và số đơn mỗi khách	43
B.11	V13–V16 — Truy vấn bổ sung của lần rà soát này	44
Tài liệu tham khảo		46

1 Kho dữ liệu CompanyX có gì?

1.1 Nguồn gốc và quy mô

Nhóm được cung cấp một bản sao lưu cơ sở dữ liệu tên **CompanyX.bak**, dung lượng 214 MB. Tên “CompanyX” chỉ là tên được đặt lại: đổi tên một cơ sở dữ liệu không đổi tên logic của các tệp dữ liệu bên trong nó, và hai tệp đó vẫn mang tên gốc.

```
sqlcmd — tên logic của tệp dữ liệu bên trong CompanyX

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t14_origin.sql
ten_logic_tep      loai      mb
-----
AdventureWorks2022  ROWS      264
AdventureWorks2022_log LOG      136

(2 rows affected)
```

CompanyX vì vậy chính là bộ dữ liệu mẫu AdventureWorks của Microsoft, mô phỏng công ty Adventure Works Cycles: một doanh nghiệp sản xuất và bán xe đạp, linh kiện, quần áo và phụ kiện đạp xe. Công ty bán hàng theo hai kênh, trực tuyến cho khách cá nhân và bán sỉ qua các cửa hàng đại lý do nhân viên kinh doanh phụ trách, trên ba khu vực Bắc Mỹ, Châu Âu và Châu Úc. Bảng 1 ghi lại xuất xứ của tệp sao lưu, đọc từ phần đầu tệp bằng lệnh **RESTORE HEADERONLY** (truy vấn V21); Bảng 2 tóm tắt quy mô kho dữ liệu.

Bảng 1: Xuất xứ tệp CompanyX.bak (truy vấn V21)

Thuộc tính	Giá trị
Tên bản sao lưu	CompanyX-Full Database Backup
Tên cơ sở dữ liệu	CompanyX
Tên logic của tệp dữ liệu	AdventureWorks2022, AdventureWorks2022_log
Ngày tạo cơ sở dữ liệu	05/11/2023
Ngày thực hiện sao lưu	07/11/2023
Máy tạo bản sao lưu	TRUNG-LEGION
Phiên bản SQL Server	16 (SQL Server 2022), mức tương thích 160
Collation	SQL_Latin1_General_CP1_CI_AS

Hai đặc điểm kỹ thuật cần ghi nhận ngay vì chúng quyết định cách thiết kế các bước sau. Thứ nhất, *hạt dữ liệu về thời gian là ngày*: toàn bộ 31.465 đơn đều có phần giờ-phút bằng 0, trải trên 1.124 ngày khác nhau trong 1.127 ngày của kỳ dữ liệu. Không có thông tin trong ngày, nên mọi phân tích thời gian chỉ xuống được tới mức ngày. Thứ hai, *mọi cột tiền đều ghi bằng USD*: 13.976 trong 31.465 đơn (44%) có gắn mã tỷ giá (AUD 6.675 đơn, CAD 3.839, GBP 3.155, EUR 172, và một ít DEM, FRF), nhưng đối chiếu cho thấy **UnitPrice** của các đơn đó bằng đúng giá niêm yết USD chứ không phải giá đã quy đổi.



Cột tỷ giá vì vậy chỉ ghi nhận khách nhìn thấy giá bằng đồng tiền nào, không phải đơn vị lưu trữ; các phép cộng doanh thu trong báo cáo không cần quy đổi tiền tệ.

Bảng 2: Quy mô kho dữ liệu CompanyX

Thông số	Giá trị
Số bảng dữ liệu	72 bảng, chia thành 6 nhóm nghiệp vụ
Số view (truy vấn được đặt tên, không lưu dữ liệu riêng)	24
Khoảng thời gian có giao dịch	31/05/2011 – 30/06/2014 (37 tháng)
Số khách hàng có mua hàng	19.119
Số đơn hàng	31.465 đơn, gồm 121.317 dòng sản phẩm
Tổng doanh thu	123,16 triệu USD
Số sản phẩm	504 sản phẩm, trong đó 295 được xếp vào 37 danh mục con thuộc 4 danh mục lớn; 266 sản phẩm thực sự xuất hiện trong đơn hàng và tất cả đều đã được phân loại
Số lãnh thổ bán hàng	10

1.2 Sáu nhóm bảng theo bộ phận nghiệp vụ

72 bảng được xếp thành 6 nhóm, mỗi nhóm ứng với một bộ phận trong công ty (Bảng 3). Với chủ đề khách hàng rời bỏ, hai nhóm Bán hàng (Sales) và Cá nhân (Person) chứa gần như toàn bộ thông tin cần thiết: khách là ai và đã mua gì. Nhóm Sản xuất (Production) cho biết tên và loại sản phẩm. Ba nhóm còn lại ghi nhận việc mua nguyên liệu từ nhà cung cấp, nhân sự và các bảng hệ thống.

Cột “Liên quan” ở Bảng 3 không phải nhận xét cảm tính. Nhóm dùng một tiêu chí cố định: một nhóm bảng được xếp mức *Cao* nếu nó chứa trực tiếp danh tính khách hàng hoặc hành vi mua của khách; mức *Trung bình* nếu nó chỉ được dùng để diễn giải hành vi đó (ví dụ tra tên và loại sản phẩm từ mã sản phẩm trong đơn); mức *Thấp* nếu không có đường nối khóa ngoại nào dẫn tới đơn hàng hay khách hàng. Theo tiêu chí này, Sales và Person ở mức Cao vì chứa bảng **Customer**, **SalesOrderHeader**, **SalesOrderDetail** và **Person**; Production ở mức Trung bình vì chỉ ba bảng trong 25 bảng của nó (**Product**, **ProductSubcategory**, **ProductCategory**) được dùng, 22 bảng còn lại phục vụ sản xuất và tồn kho; Purchasing và HumanResources ở mức Thấp vì mô tả quan hệ với nhà cung cấp và nhân sự nội bộ, không nối tới khách hàng.



Bảng 3: Các nhóm bảng trong CompanyX và mức độ liên quan đến chủ đề

Nhóm	Số bảng	Chứa thông tin gì	Liên quan
Sales (Bán hàng)	19	Khách hàng, cửa hàng đại lý, đơn hàng, chi tiết đơn, lãnh thổ, nhân viên kinh doanh, chương trình khuyến mãi, lý do mua, thẻ tín dụng, tỷ giá	Cao
Person (Cá nhân)	13	Thông tin cá nhân, địa chỉ, email, điện thoại, quốc gia/tỉnh thành	Cao
Production (Sản xuất)	25	Sản phẩm, danh mục, mẫu xe, tồn kho, lệnh sản xuất, lịch sử giá	Trung bình
Purchasing (Mua hàng)	5	Nhà cung cấp, đơn mua nguyên liệu, phương thức vận chuyển	Thấp
HumanResources (Nhân sự)	6	Nhân viên, phòng ban, lương, ca làm việc	Thấp
dbo (Hệ thống)	4	Nhật ký hệ thống, phiên bản; kèm 4 view bổ sung riêng của CompanyX	Hỗ trợ

1.3 Các bảng quan trọng và ý nghĩa của chúng

Bảng 4 liệt kê những bảng được dùng trong phân tích, số dòng thực tế và thông tin mà mỗi bảng mang lại.

Kết quả khảo sát khách cá nhân (tuổi, thu nhập, nghề nghiệp...) không được lưu thành các cột riêng mà gói chung trong một trường XML của bảng **Person.Person**. CompanyX cung cấp sẵn view **Sales.vPersonDemographics** để tách trường này thành 12 thuộc tính: ngày sinh, giới tính, tình trạng hôn nhân, thu nhập năm, học vấn, nghề nghiệp, tổng số con, số con còn ở nhà, sở hữu nhà, số xe hơi, ngày mua đầu tiên và tổng mua trong năm. Khảo sát cửa hàng được lưu và tách tương tự trong view **Sales.vStoreWithDemographics**. Cần phân biệt: view là một truy vấn được đặt tên, đọc dữ liệu từ bảng gốc mỗi khi được gọi, không phải bảng lưu sẵn kết quả; vì vậy số liệu lấy qua view luôn khớp với bảng gốc, nhưng chi phí truy vấn nằm ở bước tách XML.

So với bộ AdventureWorks gốc, CompanyX có thêm bốn view trong nhóm **dbo**. Điều này kiểm chứng được bằng ngày tạo đối tượng: 20 view chuẩn của AdventureWorks đều sinh ra cùng một thời điểm khi cơ sở dữ liệu được dựng, còn bốn view kia được tạo sáu tháng sau đó, cách nhau vài phút trong cùng một buổi làm việc.



Bảng 4: Các bảng chính phục vụ phân tích khách hàng

Bảng	Số dòng	Cho biết điều gì
Sales.Customer	19.820	Danh sách khách hàng. Mỗi khách hoặc là một cá nhân, hoặc là một cửa hàng đại lý, và thuộc về một lãnh thổ bán hàng
Sales.Store	701	Hồ sơ đại lý: tên cửa hàng, nhân viên kinh doanh phụ trách, kết quả khảo sát (loại hình, chuyên môn, doanh số năm, số nhân viên, năm mở cửa)
Person.Person	19.972	Hồ sơ cá nhân: họ tên, vai trò (khách hàng, nhân viên, nhà cung cấp...), có đồng ý nhận email khuyến mãi hay không, và kết quả khảo sát nhân khẩu học
Sales.SalesOrderHeader	31.465	Mỗi đơn hàng: ngày đặt, ngày giao, trạng thái (đã giao/đã hủy), kênh bán (online hay đại lý), nhân viên bán, tổng tiền
Sales.SalesOrderDetail	121.317	Từng sản phẩm trong đơn: sản phẩm gì, số lượng, đơn giá, mức giảm giá, chương trình khuyến mãi áp dụng
Sales.SalesOrderHeader-SalesReason	27.647	Lý do khách chọn mua (giá, khuyến mãi, chất lượng, quảng cáo TV...) gắn với từng đơn
Sales.SalesTerritory	10	10 lãnh thổ bán hàng, thuộc 3 khu vực: Bắc Mỹ, Châu Âu, Thái Bình Dương
Sales.SpecialOffer	16	Các chương trình khuyến mãi: giảm theo số lượng, theo mùa, sản phẩm mới, xả tồn kho
Production.Product	504	Sản phẩm và giá niêm yết; được xếp vào 37 danh mục con và 4 danh mục lớn (Xe đạp, Linh kiện, Quần áo, Phụ kiện)
Person.Address, CountryRegion	19.614 / 238	Địa chỉ và quốc gia của khách hàng

```
sqlcmd — ngày tạo của các view, nhóm dbo so với phần còn lại

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t15_views.sql
view_name          ngay_tao
-----
--- 20 view chuan con lai ---
dbo.SalesPersonView 2023-11-05 21:41
dbo.PersonCustomerView 2023-11-05 21:48
dbo.StoreCustomerView 2023-11-05 21:51
dbo.SalesOrderDetailView 2023-11-05 23:47

(5 rows affected)
```

Bốn view đó là: **PersonCustomerView** (khách cá nhân kèm họ tên), **StoreCustomerView** (khách đại lý kèm tên cửa hàng), **SalesPersonView** (hồ sơ nhân viên kinh doanh với chỉ tiêu, thưởng, hoa hồng, doanh số) và **SalesOrderDetailView** (chi tiết đơn hàng kèm lý do mua, chỉ lấy những dòng có áp dụng khuyến mãi). Hai view đầu tách sẵn hai nhóm khách hàng, view cuối tập trung vào các dòng hàng có khuyến mãi.

1.4 Những bảng nào thực sự cần cho chủ đề?


Khi khảo sát sơ bộ, nhóm nhận thấy hai cụm bảng liên quan trực tiếp đến chủ đề: cụm Bán hàng gồm **Customer**, **SalesOrderHeader**, **SalesOrderDetail**, **SalesTerritory**, **Store**, và cụm Cá nhân gồm **Person**. Để chắc chắn, nhóm kiểm tra lại các mối liên kết được khai báo trong cơ sở dữ liệu (Bảng 5). Kết quả xác nhận nhận định ban đầu: các bảng này nối với nhau thành một chuỗi liên mạch, đi từ khách hàng là ai đến họ đã mua gì.

Bảng 5: Các mối liên kết giữa những bảng trung tâm

Từ bảng	Qua cột	Đến bảng	Ý nghĩa
Sales.Customer	PersonID	Person.Person	Khách hàng là một cá nhân
Sales.Customer	StoreID	Sales.Store	Khách hàng là một đại lý
Sales.Customer	TerritoryID	Sales.SalesTerritory	Khách thuộc lãnh thổ nào
Sales.SalesOrderHeader	CustomerID	Sales.Customer	Đơn hàng của khách nào
Sales.SalesOrderHeader	TerritoryID	Sales.SalesTerritory	Đơn bán ở lãnh thổ nào
Sales.SalesOrderHeader	SalesPersonID	Sales.SalesPerson	Nhân viên nào bán (kênh đại lý)
Sales.SalesOrderDetail	SalesOrderID	Sales.SalesOrderHeader	Dòng sản phẩm thuộc đơn nào
Sales.SalesOrderDetail	ProductID, SpecialOfferID	Sales.SpecialOffer-Product	Sản phẩm nào, khuyến mãi nào
Sales.SalesOrderHeader-SalesReason	SalesOrderID, SalesReasonID	Sales.SalesOrderHeader, Sales.SalesReason	Lý do mua của đơn
Sales.Store	SalesPersonID	Sales.SalesPerson	Đại lý do ai phụ trách

Về bản số (cardinality): một khách có nhiều đơn, một đơn có nhiều dòng hàng (quan hệ một-nhiều). Riêng lý do mua là quan hệ nhiều-nhiều: bảng cầu **SalesOrderHeader** **SalesReason** có khóa chính ghép (**SalesOrderID**, **SalesReasonID**), nên một đơn có thể gắn nhiều lý do và mỗi lý do gắn với nhiều đơn. Khi nối bảng đơn hàng với bảng này, số dòng sẽ tăng theo số lý do của đơn; các thống kê về lý do mua ở Mục 5 vì vậy đếm riêng số lý do, số đơn và số khách.

Để trả lời trọn vẹn các câu hỏi về khách hàng, cần thêm ba nguồn ngoài danh sách trên: bảng lý do mua để biết vì sao khách mua; chuỗi **Product** → **ProductSubcategory** → **ProductCategory** để biết khách mua nhóm sản phẩm gì; và hai view nhân khẩu học đã nêu. Tất cả gộp lại khoảng 10 bảng, được vẽ lại theo ngôn ngữ nghiệp vụ trong Hình 1. Bảng Khách hàng nằm ở giữa; mỗi khách có nhiều Đơn hàng; mỗi đơn gồm nhiều Dòng sản phẩm. Khách cá nhân được mô tả thêm bằng Hồ sơ cá nhân, khách đại lý bằng Hồ sơ cửa hàng, và mỗi đơn hàng gắn với một Lý do mua.



Hình 1: Các thành phần trung tâm của kho dữ liệu nhìn từ góc độ khách hàng.

1.5 Dữ liệu này đáng tin đến đâu?

Câu trả lời có hai vế. Về mặt *liên kết*, kho dữ liệu nguyên vẹn: toàn bộ 90 khóa ngoại còn hiệu lực và đều ở trạng thái đáng tin, không có mã khách hay mã đơn bị trùng, mọi đơn hàng đều có dòng sản phẩm và ngược lại, 100% khách cá nhân có hồ sơ khảo sát, 100% cửa hàng có hồ sơ và có nhân viên phụ trách. Các phép cộng cũng khớp: không đơn nào có **TotalDue** lệch khỏi tổng ba thành phần, và không dòng nào có **LineTotal** lệch khỏi tích đơn giá, số lượng và mức giảm giá.

Nhưng về mặt *giá trị*, kho dữ liệu có một vùng hổng rõ rệt, và nó không lộ ra qua các phép kiểm tra thông thường. Dấu hiệu đầu tiên nằm ở chính khai báo của cơ sở dữ liệu: trong 89 ràng buộc kiểm tra (**CHECK**), có 8 ràng buộc đang bị *tắt* (Bảng 6). Ràng buộc bị tắt nghĩa là SQL Server không còn chặn dữ liệu sai, và cũng không bảo đảm dữ liệu sẵn có thỏa mãn điều kiện. Kiểm tra lại thì đúng như vậy: mỗi ràng buộc bị tắt đều có dữ liệu vi phạm tương ứng.

Thêm vào đó, hai cột **SalesOrderDetail.OrderQty** và **SalesOrderDetail.UnitPrice** hiện cho phép giá trị rỗng, trong khi ở AdventureWorks gốc chúng không được rỗng. Nghĩa là cấu trúc bảng đã bị sửa để chứa được dữ liệu mà thiết kế ban đầu không cho phép.

Vùng hổng tập trung vào sáu đơn hàng liên tiếp, từ 43677 đến 43682, tổng cộng 75 dòng sản phẩm. Điều đáng chú ý là mỗi đơn mang đúng *một* kiểu lỗi khác nhau (Bảng 7): đơn giá bằng 0, đơn giá âm, đơn giá rỗng, số lượng rỗng, số lượng bằng 0, số lượng âm — kèm hai đơn có ngày giao và ngày hẹn nằm trước ngày đặt gần một năm. Sự đều đặn này gợi ý đây là dữ liệu hổng được đưa vào có chủ ý chứ không phải sai sót ngẫu nhiên khi nhập liệu. Suy đoán đó kiểm chứng được, vì SQL Server có lưu dấu vết thời gian của từng đối tượng.



```
sqlcmd — dấu vết can thiệp vào cấu trúc bảng

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t16_modified.sql
ngay_tao_bang so_bang
-----
2023-05-08          69
2023-08-15           1
2023-08-16           2

(3 rows affected)
bang              tao_luc              sua_luc              check_bi_tat
-----
sysdiagrams       2023-08-15 23:24  2023-08-15 23:24      0
SalesOrderHeader  2023-05-08 12:07  2023-08-16 10:26      3
SpecialOfferProduct 2023-05-08 12:07  2023-08-16 10:26      0
TransactionHistory 2023-08-16 10:26  2023-08-16 10:26      0
Product           2023-05-08 12:07  2023-08-16 10:26      0
SalesOrderDetail   2023-08-16 10:26  2023-08-16 10:28      2
SpecialOffer       2023-05-08 12:07  2023-08-16 10:38      3

(7 rows affected)
```

Kết quả cho một dòng thời gian khép kín. Ngày 08/05/2023, 69 trong 72 bảng được sinh ra cùng một lúc — đó là lần dựng cơ sở dữ liệu AdventureWorks gốc. Ba tháng sau, trong một khoảng *mười hai phút* ngày 16/08/2023, sáu bảng bị đụng tới: **SalesOrderDetail** và **TransactionHistory** bị xóa rồi tạo lại (ngày tạo của chúng là 16/08/2023 chứ không phải 08/05/2023), còn **SalesOrderHeader**, **SpecialOffer**, **Product** và **SpecialOfferProduct** bị sửa cấu trúc. Đúng ba bảng trong số đó — **SalesOrderHeader**, **SalesOrderDetail**, **SpecialOffer** — là ba bảng đang mang toàn bộ 8 ràng buộc bị tắt, theo tỷ lệ 3–2–3. Không bảng nào khác trong 72 bảng có ràng buộc bị tắt.

Việc **SalesOrderDetail** bị *tạo lại* thay vì chỉ sửa cũng giải thích luôn vì sao hai cột **OrderQty** và **UnitPrice** hiện cho phép rỗng: bảng được dựng lại với định nghĩa cột khác bản gốc. Ba tháng sau nữa, ngày 05/11/2023, cơ sở dữ liệu được đặt tên CompanyX và bốn view **dbo** được thêm vào; hai ngày sau thì bản sao lưu được tạo (Bảng 1).

Nói cách khác, ba nhóm bảng chúng đọc lập đều chỉ về cùng một kết luận: mẫu hình lỗi quá đều để là ngẫu nhiên; tập ràng buộc bị tắt khớp chính xác với tập lỗi có trong dữ liệu; và dấu vết thời gian cho thấy đúng những bảng đó bị can thiệp trong một buổi làm việc ngắn. Đây là dữ liệu hổng được cài vào có chủ đích. Nhận định này quan trọng về mặt phương pháp: nó có nghĩa vùng hổng là hữu hạn và xác định được, không phải triệu chứng của một quy trình thu thập dữ liệu kém chất lượng lan khắp kho.

Đây cũng là lý do các phép kiểm tra cộng trừ ở trên không phát hiện được gì: với đơn 43677, tất cả đơn giá bằng 0 nên tổng dòng hàng bằng 0 và bằng đúng **SubTotal**; phép cộng khớp hoàn hảo trong khi bản ghi hoàn toàn vô nghĩa, vì đơn vẫn mang 747,10 USD tiền thuế và 233,47 USD phí vận chuyển cho 24 sản phẩm giá 0 đồng. *Nhất quán về số học không đồng nghĩa với dùng được.*



Ngoài đơn hàng, bảng chương trình khuyến mãi cũng có ba dòng hồng (Bảng 8): chương trình 3 có số lượng tối đa –24 (lẽ ra là 24, đúng như tên gọi “Volume Discount 15 to 24”), còn chương trình 15 và 16 có ngày kết thúc nằm trước ngày bắt đầu. Hệ quả lan sang dữ liệu bán hàng: 169 dòng hàng của mẫu xe Mountain-500 Silver, trị giá 25.899 USD ở kênh đại lý, được áp mức giảm 40% của chương trình 16 tại thời điểm chương trình đó, theo đúng ngày ghi trong bảng, chưa hề bắt đầu.

Bảng 9 tổng hợp toàn bộ vấn đề tìm thấy cùng cách xử lý.

Bảng 6: Tám ràng buộc kiểm tra đang bị tắt trong cơ sở dữ liệu (truy vấn V17)

Bảng	Ràng buộc	Điều kiện lẽ ra phải giữ
SalesOrderDetail	CK_SalesOrderDetail_OrderQty	Số lượng phải lớn hơn 0
SalesOrderDetail	CK_SalesOrderDetail_UnitPrice	Đơn giá không được âm
SalesOrderHeader	CK_SalesOrderHeader_DueDate	Ngày hẹn không sớm hơn ngày đặt
SalesOrderHeader	CK_SalesOrderHeader_ShipDate	Ngày giao không sớm hơn ngày đặt
SalesOrderHeader	CK_SalesOrderHeader_SubTotal	Tiền trước thuế không được âm
SpecialOffer	CK_SpecialOffer_DiscountPct	Mức giảm giá không được âm
SpecialOffer	CK_SpecialOffer_EndDate	Ngày kết thúc không sớm hơn ngày bắt đầu
SpecialOffer	CK_SpecialOffer_MaxQty	Số lượng tối đa không được âm

Bảng 7: Sáu đơn hàng hồng, mỗi đơn một kiểu lỗi (truy vấn V18)

Đơn	Dòng hồng	Kiểu lỗi	Ghi chú
43677	12	Đơn giá bằng 0	Vấn thu 980,57 USD thuế và phí cho 24 sản phẩm giá 0
43678	19	Đơn giá âm	Tổng đơn –8.563,45 USD
43679	3	Đơn giá rỗng	Cột lẽ ra không được rỗng
43680	15	Số lượng rỗng	Ngày giao và ngày hẹn trước ngày đặt gần một năm
43681	21	Số lượng bằng 0	Ngày giao và ngày hẹn trước ngày đặt gần một năm
43682	5	Số lượng âm	Tổng đơn –3.387,74 USD
<i>Tổng</i>	<i>75</i>		<i>Cả sáu đều là khách đại lý, kênh bán sỉ</i>

Bảng 8: Ba dòng hồng trong bảng chương trình khuyến mãi (truy vấn V19)

Mã	Tên chương trình	Lỗi
3	Volume Discount 15 to 24	Số lượng tối đa ghi –24, lẽ ra là 24
15	Half-Price Pedal Sale	Kết thúc 14/08/2012, bắt đầu 14/07/2013
16	Mountain-500 Silver Clearance	Kết thúc 30/05/2013, bắt đầu 31/03/2014; kéo theo 169 dòng hàng trị giá 25.899 USD được giảm 40% ngoài thời hạn

Báo cáo dùng hai tập dữ liệu và ghi rõ ở từng chỗ. *Tập mô tả* là toàn bộ dữ liệu gốc, dùng cho các thống kê ở Mục 3 đến Mục 5 để giữ đúng con số của kho dữ liệu. *Tập phân*

Bảng 9: Các vấn đề về chất lượng dữ liệu và cách xử lý

Vấn đề	Chi tiết	Cách xử lý
701 dòng Customer không có đơn	PersonID rỗng, StoreID có giá trị; không có đơn hàng nào	Bỏ ra khỏi tập phân tích; 19.119 khách còn lại đều có đơn
8 ràng buộc CHECK bị tắt	Xem Bảng 6. Ràng buộc bị tắt nên máy chủ không còn chặn dữ liệu sai	Không bật lại (chỉ đọc); dùng làm chỉ dẫn để đi tìm dữ liệu vi phạm
2 cột bị nối thành cho phép rỗng	OrderQty và UnitPrice của SalesOrderDetail ; ở AdventureWorks gốc hai cột này không được rỗng	Xử lý giá trị rỗng như dữ liệu hỏng, không quy về 0
6 đơn hỏng, 75 dòng sản phẩm	Đơn 43677–43682, mỗi đơn một kiểu lỗi (Bảng 7). Cả sáu đều thuộc khách đại lý	Giữ trong số liệu mô tả để nêu đúng hiện trạng; loại khỏi tập phân tích churn
3 dòng hỏng ở bảng khuyến mãi	Bảng 8; kéo theo 169 dòng hàng được giảm giá ngoài thời hạn	Không dùng StartDate , EndDate , MaxQty của bảng khuyến mãi làm biến phân tích
315 đơn trạng thái 6	Cột Status chỉ có hai giá trị: 5 (31.150 đơn) và 6 (315 đơn, tổng 1,18 triệu USD). Theo tài liệu AdventureWorks, 5 = đã giao, 6 = đã hủy	Giữ trong số liệu mô tả; không tính là lần mua trong tập phân tích churn
73,7% đơn dồn vào 12 tháng cuối	23.202 trong 31.465 đơn có ngày đặt sau 30/06/2013; kênh online tăng vọt từ quý 3/2013	Chọn mốc gắn nhãn sao cho khách có đủ thời gian quan sát (Mục 6.1)
Một số trường chữ chưa chuẩn	“Bachelors ” thừa khoảng trắng; thu nhập ghi theo khoảng chứ không phải số	Chuẩn hóa trước khi dùng làm biến phân tích
Ba trường không dùng được	Status chỉ có hai trong sáu giá trị tài liệu mô tả; ShipDate luôn bằng ngày đặt cộng 7 ngày ở 31.454 trên 31.465 đơn; 30.334 đơn dùng thẻ đã hết hạn trước ngày đặt	Không dùng làm biến phân tích

tích churn loại 321 đơn: 315 đơn hủy và sáu đơn hỏng ở Bảng 7. Bảng 10 cho thấy việc loại này làm mất 124 khách (những khách chỉ có đơn hủy) và khoảng 1% đơn, dòng hàng và doanh thu. Sáu đơn hỏng không làm mất thêm khách nào, vì cả sáu đều thuộc các đại lý còn nhiều đơn hợp lệ khác; nhờ vậy nhãn rời bỏ không đổi so với khi chỉ loại đơn hủy và đơn âm. Để tiện đối chiếu với các con số đã công bố trong nhóm, các bảng ở Mục 6 vẫn trình bày kết quả trên tập gốc và ghi kèm kết quả trên tập đã lọc ở những chỗ có khác biệt; chênh lệch ở tỷ lệ rời bỏ tổng thể là 16,9% so với 17,6%.

Bảng 10: Quy mô dữ liệu trước và sau khi loại đơn hủy và đơn hỏng (truy vấn V02e)

Tập dữ liệu	Khách	Đơn	Dòng hàng	Trước thuế (USD)	Tổng phải trả (USD)
Gốc (tập mô tả)	19.119	31.465	121.317	109.784.736	123.155.141
Đã lọc (tập phân tích churn)	18.995	31.144	120.072	108.748.472	121.986.324

2 Chủ đề khách hàng rời bỏ trên kho dữ liệu này

Khách hàng rời bỏ (customer churn) là khách đã ngừng mua hàng của doanh nghiệp. Trong kho dữ liệu không có cột nào ghi “khách này đã rời bỏ”: CompanyX là doanh nghiệp bán lẻ, khách không ký hợp đồng và không thông báo khi ngừng mua. Muốn biết ai đang rời bỏ và tại sao, trước hết phải hiểu khách hàng là ai, họ thích mua gì, mua như thế nào, và người ở lại khác gì người ra đi. Phần Dataset Analysis là bước làm quen đó, dựa trên các bảng đã xác định ở Mục 1.

Mỗi nhận định trong các mục sau đều đi kèm con số lấy từ kho dữ liệu và mã truy vấn để đối chiếu; ở những chỗ cần thiết, báo cáo dẫn thêm kiến thức về quản trị khách hàng để giải thích vì sao chọn cách đo đó thay vì cách khác.

Công cụ sử dụng gồm Microsoft SQL Server 2022 (Developer Edition, chạy trong Docker trên Linux) để khôi phục và lưu dữ liệu, DBeaver và `sqlcmd` để truy vấn, và LaTeX để trình bày. Các câu truy vấn được lưu trong tệp đính kèm `verify_queries.sql` (đánh mã V01–V16, kết quả chạy trong `verify_results.txt`), tệp `tour_queries.sql` (các truy vấn minh họa nội dung kho ở Phụ lục B) và ba tệp `analyze_queries*.sql`; mỗi con số trong báo cáo được ghi kèm mã truy vấn tương ứng khi cần đối chiếu.

3 Khách hàng của chúng ta là ai?

3.1 Hai nhóm khách hàng rất khác nhau

Trong 19.119 khách đã mua hàng, 18.484 người (96,7%) là khách cá nhân mua online và chỉ 635 (3,3%) là cửa hàng đại lý. Nhìn theo doanh thu thì bức tranh đảo ngược: nhóm đại lý ít ỏi mang lại 74% doanh thu, với giá trị mỗi đơn cao gấp 20 lần đơn của khách cá nhân (Bảng 11).

Bảng 11: Hai nhóm khách hàng của CompanyX

Nhóm	Số khách	Số đơn	Doanh thu	Trung bình/đơn
Khách cá nhân (online)	18.484	27.659	32,4 triệu USD (26%)	1.173 USD
Đại lý	635	3.806	90,7 triệu USD (74%)	23.834 USD

Sự tập trung này còn rõ hơn khi xếp toàn bộ khách theo tổng số tiền đã chi và chia làm năm phần bằng nhau: 20% khách chi nhiều nhất tạo ra 89,7% doanh thu, còn 60% khách ở nhóm chi ít nhất chỉ đóng góp 2%. Đây là nguyên lý 80/20 quen thuộc trong quản trị khách hàng. Tính trên toàn bộ 37 tháng (truy vấn V03), một đại lý đặt trung bình 6,0 đơn và mang lại 142.856 USD; một khách cá nhân đặt 1,5 đơn và mang lại 1.755 USD. Tỷ lệ 20 lần ở cấp đơn trở thành khoảng 80 lần ở cấp khách hàng, vì đại lý vừa đặt đơn lớn hơn vừa đặt nhiều đơn hơn. Reichheld và Sasser (1990) đã chỉ ra rằng giữ một khách cũ rẻ hơn nhiều so với tìm một khách mới, nên nguồn lực giữ chân cần dồn vào nhóm có giá trị cao. Vì hai nhóm khách khác nhau cả về cách mua lẫn giá trị, các phân tích tiếp theo tách riêng chúng thay vì gộp chung.

3.2 Chân dung khách cá nhân

Hồ sơ khảo sát của 18.484 khách cá nhân (Bảng 12; tuổi tính tại ngày cuối dữ liệu 30/06/2014, ngày sinh trong dữ liệu trải từ 1910 đến 1980 nên không có khách dưới 33 tuổi) cho thấy một tệp khách khá đồng nhất: phần lớn ở tuổi 40–59, thu nhập 25–75 nghìn USD một năm, đã kết hôn, có con, có nhà riêng và xe hơi, sống ở Mỹ, Úc hoặc Tây Âu. Tỷ lệ nam nữ gần như bằng nhau.

Bảng 12: Chân dung khách cá nhân

Đặc điểm	Tỷ lệ
Giới tính	Nam 50,6% – Nữ 49,4%
Độ tuổi	30–39: 12% – 40–49: 33% – 50–59: 29% – 60+: 26%
Hôn nhân	Đã kết hôn 54% – Độc thân 46%
Thu nhập/năm	Dưới 25k: 16% – 25–50k: 31% – 50–75k: 30% – 75–100k: 15% – Trên 100k: 9%
Nghề nghiệp	Chuyên môn 30% – Lao động kỹ thuật 25% – Quản lý 17% – Văn phòng 16% – Lao động phổ thông 13%
Học vấn	Cử nhân 29% – Cao đẳng/dở dang 27% – Trung học 18% – Sau đại học 17%
Gia đình	72% có con; 68% có nhà riêng; 77% có ít nhất 1 xe hơi
Quốc gia	Mỹ 42% – Úc 19% – Anh 10% – Pháp 10% – Đức 10% – Canada 9%


Dữ liệu không ghi nhận mục đích sử dụng, nhưng hồ sơ này (trung niên, có thu nhập ổn định, có nhà và xe hơi, ở các nước phát triển) gợi ý đây phần lớn là người mua xe đạp để giải trí và rèn luyện sức khỏe hơn là để đi lại hằng ngày. Tỷ lệ nam nữ cân bằng cho thấy sản phẩm không nghiêng về nam giới như người ta thường nghĩ về xe đạp thể thao.

3.3 Chân dung đại lý

701 cửa hàng trong hệ thống chia khá đều thành ba loại: nhà sản xuất xe đạp (238), cửa hàng xe đạp (231) và cửa hàng bán online (232). Về chuyên môn, 300 cửa hàng thiên về xe đường trường, 246 về xe địa hình và 155 về xe du lịch. Doanh số năm của cửa hàng dao động từ 300 nghìn đến 3 triệu USD, trong đó 204 cửa hàng ở mức 3 triệu; quy mô trung bình 40 nhân viên; năm mở cửa từ 1970 đến 2001. Đó là những doanh nghiệp cỡ vừa, hoạt động lâu năm và có nhân viên kinh doanh của CompanyX phụ trách trực tiếp, nên mối quan hệ cá nhân giữa hai bên có thể ảnh hưởng lớn đến việc họ ở lại hay ra đi.

3.4 Khách hàng ở đâu?

Hai vùng của Mỹ (Southwest, Northwest) và Úc là ba thị trường đông khách nhất (Hình 2). Úc đông khách thứ hai (3.625 khách) nhưng doanh thu chỉ đứng thứ tư (11,8 triệu USD) vì gần như toàn khách online. Ngược lại, ba vùng Southeast, Central và Northeast của Mỹ có rất ít khách nhưng doanh thu cao, vì gần như toàn đại lý. Cơ cấu này sẽ giải thích một phần khác biệt về tỷ lệ rời bỏ giữa các vùng ở Mục 6.




Hình 2: Số khách hàng theo lãnh thổ bán hàng (19.119 khách đã có ít nhất một đơn; truy vấn V14). Nếu đếm cả 701 bản ghi khách không có đơn thì tổng là 19.820 và thứ tự các vùng không đổi.

4 Khách hàng thích mua sản phẩm gì?

4.1 Doanh thu và độ phủ khách hàng theo danh mục sản phẩm

Tính theo giá bán trước thuế và phí vận chuyển (tổng 109,8 triệu USD; cộng thêm 10,2 triệu thuế và 3,2 triệu phí vận chuyển sẽ ra con số 123,16 triệu ở Bảng 2), xe đạp chiếm 94,6 triệu USD, tức 86%; linh kiện 11,8 triệu (11%), quần áo 2,1 triệu (2%) và phụ kiện 1,3 triệu (1%). Nhưng nếu đếm số khách từng mua thì thứ tự đảo lại: phụ kiện có 15.461 khách, xe đạp 9.719, quần áo 7.327 và linh kiện 580 (Hình 3).



Hình 3: Số khách từng mua theo danh mục: phụ kiện tiếp cận được nhiều khách nhất, xe đạp mang lại doanh thu lớn nhất.

Những sản phẩm được nhiều khách mua nhất đều là đồ nhỏ, rẻ và phải thay định kỳ: bình nước 30 oz (4.073 khách), săm xe địa hình (2.960), bộ vá săm (2.950), săm xe đường trường (2.226), mũ bảo hiểm Sport-100 ba màu (khoảng 2.000–2.150 khách mỗi màu) và mũ lưỡi trai AWC (2.132).

Xe đạp là món hàng bền, vài năm mới mua lại một lần, còn phụ kiện là thứ hay hỏng, hay hết và được nhiều khách mua nhất. Trong marketing, hàng lâu bền có chu kỳ mua

lại dài nên tự nó không tạo ra sự gắn bó thường xuyên; các nhà bán lẻ thường dùng hàng tiêu hao đi kèm để tăng số lần tiếp xúc với khách, theo kiểu bán dao cạo một lần và bán lưỡi dao nhiều lần. Với CompanyX, phụ kiện là kênh tiếp xúc sẵn có trong khoảng thời gian dài giữa hai lần mua xe. Liệu việc mua phụ kiện có thực sự giúp giữ chân khách hay không sẽ được xem xét ở Mục 6.

4.2 Khách cá nhân và đại lý mua những thứ khác nhau

Ở kênh online, xe đường trường được nhiều khách chọn nhất (6.397 khách), kế đến là xe địa hình (4.089) và xe du lịch (2.143). Sở thích dòng xe không khác nhau giữa nam và nữ: xe đường trường có 3.224 khách nữ và 3.173 khách nam; xe địa hình có 2.069 nữ và 2.020 nam. Tỷ lệ khách có mua xe cao nhất ở tuổi 40–49 (59%) và thấp dần ở nhóm trên 60 (40%), tức người trẻ hơn thiên về mua xe, người lớn tuổi thiên về phụ kiện.

Đại lý mua theo cách hoàn toàn khác: số lượng lớn (39 nghìn xe đường trường, 23 nghìn xe địa hình) và là nhóm duy nhất mua linh kiện rời như khung xe, bánh xe, với doanh thu hơn 10 triệu USD. Họ là khách doanh nghiệp đúng nghĩa, mua để lắp ráp hoặc bán lại.

4.3 Khách có mua nhiều loại hàng khác nhau không?

Trong 18.484 khách online, 7.892 người (43%) chỉ mua một loại hàng, 8.570 (46%) mua hai loại và 2.022 (11%) mua cả ba loại. Đáng chú ý, trong 9.132 người từng mua xe có 7.677 (84%) cũng mua thêm phụ kiện hoặc quần áo. Người đã mua xe rất sẵn lòng mua thêm đồ đi kèm, nghĩa là việc bán kèm đang được khai thác khá tốt. Nhóm ít gắn bó nhất là 43% khách chỉ mua đúng một loại hàng, đa số là vài món phụ kiện lẻ.


5 Khách hàng mua như thế nào?

5.1 Mua bao nhiêu lần?

Hơn 60% khách chỉ mua đúng một lần (11.649 người); 29% mua hai lần; chỉ 10% mua từ ba lần trở lên (Hình 4). Trung bình mỗi khách mua 1,65 lần. Nhóm mua từ sáu lần trở lên gồm 337 khách, trong đó 293 người (87%) là đại lý đặt hàng định kỳ và 44 người là khách cá nhân.

Với khách cá nhân mua từ hai lần trở lên, hai lần mua cách nhau trung bình 317 ngày, và 38% số lần quay lại cách lần trước hơn một năm. Với đại lý, khoảng cách trung bình chỉ 99 ngày, tức đặt hàng gần như mỗi quý. Khách cá nhân mua thưa, phần lớn là khách một lần, và nếu có quay lại thì thường gần một năm sau; đại lý mua đều đặn. Sự khác biệt này quyết định cách hiểu “rời bỏ” ở Mục 6: một khách cá nhân im lặng sáu tháng là chuyện bình thường, nhưng một đại lý im lặng sáu tháng, tức bỏ qua hai kỳ đặt hàng, là bất thường.

Số lần mua và khoảng cách giữa các lần mua được xem trước mọi con số khác vì đây là hai trong ba yếu tố của mô hình RFM (Hughes, 1994): khách mua gần đây không




Hình 4: Số lần mua của 19.119 khách hàng.

(Recency), mua thường xuyên không (Frequency) và chi bao nhiêu (Monetary). Mô hình BG/NBD của Fader, Hardie và Lee (2005) cũng chỉ dùng đúng hai đại lượng này, số lần mua lặp lại và thời điểm mua cuối, để ước lượng xác suất khách còn “hoạt động” trong bối cảnh không hợp đồng.

5.2 Mua vào lúc nào?

Hình 5 vẽ tổng số đơn của cả hai kênh theo quý (truy vấn V09a). Bước nhảy từ 1.575 đơn (quý 2/2013) lên 5.320 đơn (quý 3/2013) đến gần như hoàn toàn từ kênh online: số đơn online tăng từ 1.192 lên 4.866, trong khi đơn đại lý chỉ tăng từ 383 lên 454 và sau đó dao động quanh 450 đơn mỗi quý. Quý 2/2014 của kênh đại lý chỉ có 181 đơn, thấp bất thường so với các quý trước; dữ liệu kết thúc đúng ngày 30/06/2014 nên chưa rõ đây là sụt giảm thật hay do cách ghi nhận đơn cuối kỳ.

Dữ liệu chưa đủ để kết luận về mùa vụ. Khi tách theo năm (V09b), số đơn online mỗi tháng tăng hơn 5 lần từ 2013 sang 2014, nên tổng theo tháng bị chi phối bởi tăng trưởng chứ không phải chu kỳ trong năm; hơn nữa năm 2011 chỉ có từ tháng 6 và năm 2014 chỉ đến tháng 6, mỗi tháng không có đủ số năm quan sát để so sánh. Nhóm không đưa ra nhận định về tháng cao điểm.



Hình 5: Tổng số đơn hàng (cả hai kênh) theo quý; bước nhảy từ quý 3/2013 đến từ kênh online.

Hệ quả là phần lớn khách cá nhân là khách mới, chỉ xuất hiện trong 12 tháng cuối. Họ chưa có đủ thời gian để chứng tỏ mình là khách trung thành hay đã rời bỏ, nên không thể gắn nhãn “rời bỏ” cho toàn bộ khách một cách máy móc (Mục 6.1).

5.3 Vì sao họ mua?

Lý do mua chỉ được ghi nhận cho kênh online: 23.012 trong 27.659 đơn online (83,2%) có ít nhất một lý do, không đơn đại lý nào có (truy vấn V08a, V08b). Một đơn có thể gắn nhiều lý do: 18.530 đơn có một lý do, 4.329 đơn có hai và 153 đơn có ba, tổng cộng 27.647 dòng lý do. Bảng 13 đếm theo số đơn để tránh một đơn bị tính nhiều lần.

Bảng 13: Lý do mua của đơn hàng online (23.012 đơn có ghi lý do; một đơn có thể có nhiều lý do)

Lý do	Số đơn	Tỷ lệ trên 23.012 đơn	Số khách
Giá cả	17.473	75,9%	14.529
Khuyến mãi	3.515	15,3%	3.121
Thương hiệu nhà sản xuất	1.746	7,6%	1.722
Chất lượng	1.551	6,7%	1.551
Khác	1.395	6,1%	1.337
Đánh giá của người khác	1.245	5,4%	1.218
Quảng cáo truyền hình	722	3,1%	657

Giá cả được nêu ở ba phần tư số đơn có ghi lý do; các yếu tố về thương hiệu, chất lượng và quảng cáo đều dưới 8%. Vì lý do mua do khách tự khai và chỉ có ở kênh online, kết luận “khách quan tâm đến giá” áp dụng cho khách cá nhân, không suy ra cho đại lý.

Về khuyến mãi thực tế (V08c): 115.884 trong 121.317 dòng hàng (95,5%) không có giảm giá. Các chương trình giảm giá trong bảng **SpecialOffer** đều thuộc nhóm “Reseller”, nhưng vẫn xuất hiện ở 2.151 dòng hàng online (3,6% dòng online) bên cạnh 3.282 dòng hàng đại lý (5,4%). Nói cách khác, cả hai kênh đều hiếm khi có khuyến mãi, kênh online ít hơn một chút. Giá trị mỗi đơn online tăng theo thu nhập, từ 948 USD ở nhóm dưới 25 nghìn đến 1.527 USD ở nhóm trên 100 nghìn. Liệu một tập khách nêu “giá” làm lý do mua chính nhưng ít được khuyến mãi có dễ rời bỏ hơn hay không là câu hỏi mà dữ liệu hiện có chưa trả lời được.

6 Ai đang rời bỏ và dấu hiệu nào đi kèm?

6.1 Thế nào là “rời bỏ” đối với doanh nghiệp bán lẻ?

Vì không có hợp đồng, việc rời bỏ phải được suy ra từ hành vi: khách rời bỏ là khách không mua gì trong một khoảng thời gian đủ dài. Câu hỏi là “đủ dài” là bao lâu và tính từ lúc nào.

Kho dữ liệu không có cột nhãn rời bỏ nào (truy vấn V04a chỉ tìm thấy **ActiveFlag** của nhà cung cấp). Nhãn vì vậy phải được tạo theo quy ước.

Cách đơn giản nhất là đếm ngược từ ngày cuối cùng có dữ liệu (30/06/2014) và gọi mọi khách không mua trong W tháng cuối là rời bỏ (V04e). Với $W = 6$ tháng, 8.765 trong 19.119 khách (45,8%) bị gắn nhãn rời bỏ; với $W = 12$ tháng chỉ còn 1.016 khách (5,3%). Cách này có hai lỗi: mẫu số gồm cả hàng nghìn khách mới mua lần đầu trong W tháng cuối, những người chưa hề có cơ hội mua lại; và ngưỡng 12 tháng bị khớp với chính đợt bùng nổ khách mới từ quý 3/2013, khiến tỷ lệ 5,3% thấp một cách giả tạo.

Nhóm đề xuất chia thời gian làm hai giai đoạn. Giai đoạn theo dõi kéo dài từ 31/05/2011 đến 30/06/2013: chỉ xét những khách đã mua lần đầu trong giai đoạn này, vì họ có ít nhất 12 tháng để thể hiện. Giai đoạn kiểm tra kéo dài từ 01/07/2013 đến 30/06/2014: khách được coi là rời bỏ nếu không có đơn nào trong giai đoạn này, ngược lại là ở lại. Theo cách này (V04b, tính trên tập gốc) có 6.206 khách đủ điều kiện xét, trong đó 1.050 người rời bỏ (16,9%) và 5.156 ở lại (83,1%); trên tập đã lọc đơn hủy và đơn âm (V04c) là 1.080 trên 6.148 (17,6%). Nhìn lại toàn bộ lịch sử mua (V04g, chỉ để mô tả hồi cứu, không dùng làm biến dự báo), người rời bỏ trung bình có 1,6 đơn và khoảng cách từ đơn đầu đến đơn cuối là 104 ngày; người ở lại có 2,6 đơn và 547 ngày.

Nếu áp dụng cùng nguyên tắc “đủ thời gian quan sát” cho ngưỡng 6 tháng (mốc 31/12/2013, kỳ kiểm tra 01/01–30/06/2014; V04d), có 13.097 khách đủ điều kiện và 8.765 người (66,9%) không mua trong kỳ kiểm tra. Con số này cao hơn hẳn 16,9% của ngưỡng 12 tháng không phải vì hai cách tính mâu thuẫn, mà vì hai tập khách đủ điều kiện khác nhau: ngưỡng 6 tháng đưa thêm 6.891 khách mới của nửa cuối 2013, hầu hết mới mua một chiếc xe và chưa quay lại trong sáu tháng. Điều này cho thấy tỷ lệ rời bỏ phụ thuộc mạnh vào ngưỡng và vào nhóm khách gia nhập, và mọi so sánh giữa các ngưỡng phải nêu rõ cả hai.

Việc tách một giai đoạn theo dõi và một giai đoạn kiểm tra là cách làm quen thuộc trong nghiên cứu khách hàng không hợp đồng: Fader, Hardie và Lee (2005) ước lượng mô hình trên kỳ hiệu chuẩn rồi đánh giá trên kỳ giữ lại; Reinartz và Kumar (2000) cũng xác định khách còn hoạt động hay không dựa trên hành vi mua sau một mốc thời gian. Các nghiên cứu này không quy định ngưỡng 12 tháng; con số 12 tháng ở đây là lựa chọn của nhóm, dựa trên việc khách cá nhân của CompanyX quay lại trung bình sau 317 ngày và dữ liệu chỉ còn đúng 12 tháng sau mốc.

Cần nói rõ đây là *nhãn rời bỏ theo quy ước quan sát 12 tháng*, không phải bằng chứng khách đã rời bỏ vĩnh viễn. Mục 5 cho thấy 38% số lần quay lại của khách cá nhân cách lần mua trước hơn một năm, và trong toàn bộ dữ liệu có 3.486 khách từng quay lại sau khoảng nghỉ dài hơn 365 ngày (truy vấn V13). Một phần khách bị gắn nhãn “rời bỏ” vì thế vẫn có thể mua tiếp sau khi dữ liệu kết thúc. Quy ước 12 tháng là sự đánh đổi: cửa sổ ngắn hơn sẽ gắn nhãn sai nhiều khách chỉ mua thừa, cửa sổ dài hơn sẽ không còn đủ dữ liệu để kiểm tra. Khi có thêm dữ liệu, nên thử lại với cửa sổ 18 hoặc 24 tháng.

Một nguyên tắc quan trọng khi tính các chỉ tiêu ở những mục sau: mọi đặc điểm dùng để so sánh nhóm rời bỏ và nhóm ở lại (số lần mua, loại hàng đã mua) đều *chỉ tính trên*


giai đoạn theo dõi, tức trước mốc 30/06/2013. Nếu tính cả giai đoạn kiểm tra thì bản thân đặc điểm đã chứa kết quả cần dự báo, và mọi so sánh sẽ vô nghĩa.

6.2 Đại lý rời bỏ nhiều gần gấp đôi khách cá nhân

Tỷ lệ rời bỏ của đại lý là 28,6% (153 trên 535), so với 15,8% ở khách cá nhân (897 trên 5.671). Nhóm khách mang lại 74% doanh thu lại là nhóm rời bỏ nhiều nhất. Dữ liệu không cho biết đại lý ngừng mua vì lý do gì, nhưng vì họ vốn đặt hàng gần như mỗi quý, một đại lý không đặt hàng suốt 12 tháng là sự gián đoạn lớn so với nhịp mua thông thường của họ. Điều này đặt ra câu hỏi cho giai đoạn sau: với đại lý, có nên dùng ngưỡng ngắn hơn 12 tháng, ví dụ một hoặc hai kỳ đặt hàng bị bỏ qua, để định nghĩa rời bỏ hay không.

6.3 Khách tại Úc có tỷ lệ rời bỏ quan sát thấp nhất

Tỷ lệ rời bỏ theo lãnh thổ chênh nhau tới 10 lần (Hình 6): Canada 42%, Southeast 38%, Central 37%, ba vùng Northwest, Southwest, Northeast khoảng 27%; Pháp 16%, Đức 11%, Anh 9%; Úc chỉ 4%.



Hình 6: Tỷ lệ rời bỏ theo lãnh thổ (trong 6.206 khách đủ điều kiện xét).

Một phần khác biệt đến từ cơ cấu khách: Bắc Mỹ có nhiều đại lý, nhóm rời bỏ cao, còn Úc gần như toàn khách online. Nhưng ngay giữa các thị trường online tương tự nhau như Úc với Anh, Pháp, Đức, Úc vẫn thấp hơn rõ rệt. Dữ liệu hiện có chưa giải thích được điều này; mức độ cạnh tranh hay chính sách bán hàng ở từng thị trường là những hướng đáng tìm hiểu ở các phần sau.

6.4 Số lần mua trước mốc và tỷ lệ rời bỏ


Theo mô hình RFM, khách đã mua nhiều lần thường được kỳ vọng gắn bó hơn. Dữ liệu CompanyX lại cho kết quả ngược lại khi số lần mua chỉ được đếm trong giai đoạn theo dõi (Bảng 14). Trong 5.671 khách cá nhân đủ điều kiện xét, 5.357 người mới mua đúng một lần trước mốc và 13,4% trong số họ rời bỏ; 311 người đã mua hai lần trước mốc

thì có tới 57,2% rời bỏ (3 khách còn lại mua 3–5 lần, không ai rời bỏ, cỡ mẫu quá nhỏ để nhận xét). Với đại lý, tỷ lệ rời bỏ cao nhất ở nhóm đã đặt 3–5 đơn (34,2%) và thấp hơn ở nhóm đặt từ 6 đơn (23,0%).

Bảng 14: Tỷ lệ rời bỏ theo số lần mua trong giai đoạn theo dõi (trước 30/06/2013)

Nhóm khách	Số lần mua trước mốc	Đủ điều kiện	Rời bỏ	Tỷ lệ
Khách cá nhân	1 lần	5.357	719	13,4%
Khách cá nhân	2 lần	311	178	57,2%
Khách cá nhân	3–5 lần	3	0	0,0%
Đại lý	1–2 lần	147	34	23,1%
Đại lý	3–5 lần	266	91	34,2%
Đại lý	6 lần trở lên	122	28	23,0%
<i>Tổng</i>		<i>6.206</i>	<i>1.050</i>	<i>16,9%</i>


Nguồn: truy vấn V05a. Cột “Đủ điều kiện” cộng lại bằng 5.671 khách cá nhân và 535 đại lý.



Hình 7: Tỷ lệ rời bỏ theo số lần mua *trước mốc* 30/06/2013 (truy vấn V05a). Cỡ mẫu lần lượt là 5.357, 311, 147, 266 và 122 khách.

Kết quả này giữ nguyên chiều hướng trong từng nhóm khách gia nhập: với khách cá nhân mua lần đầu năm 2011, tỷ lệ rời bỏ là 19% ở nhóm một lần và 41% ở nhóm hai lần; năm 2012 là 7% và 70%; nửa đầu 2013 là 20% và 63%. Vậy đây không đơn thuần là chuyện khách cũ đã “hết chu kỳ”.

Nhóm chưa có đủ dữ liệu để giải thích chắc chắn. Một cách hiểu hợp lý là với hàng lâu bền, lần mua thứ hai trong vòng hai năm đầu thường đã đáp ứng trọn nhu cầu (ví dụ mua xe rồi mua nốt phụ kiện đi kèm), nên khách không còn lý do quay lại; trong khi khách mới mua một chiếc xe vẫn còn nhu cầu mua thêm. Cũng cần lưu ý AdventureWorks là dữ liệu mô phỏng, và hành vi trong đó có thể không giống hoàn toàn khách hàng thực. Dù giải thích nào đúng, kết luận thực tiễn là số lần mua trong quá khứ *không* thể dùng một mình như chỉ báo gắn bó ở CompanyX; mô hình dự đoán sau này cần xét nó cùng với thời điểm gia nhập và loại hàng đã mua.



Hình 8: Chiều hướng “mua nhiều hơn thì rời bỏ nhiều hơn” lặp lại ở cả ba nhóm khách gia nhập (V05c, khách cá nhân).

Bản nháp đầu của báo cáo từng đưa ra kết luận ngược lại (khách đã mua lần hai chỉ rời bỏ dưới 5%). Sai sót nằm ở chỗ số lần mua khi đó được đếm trên toàn bộ dữ liệu, kể cả giai đoạn kiểm tra, nên ai có đơn sau mốc đều vừa được đếm thêm một lần mua vừa được gắn nhãn ở lại. Đây là lỗi rò rỉ dữ liệu điển hình và đã được sửa.

6.5 Loại hàng đã mua trước mốc và tỷ lệ rời bỏ


Cùng nguyên tắc chỉ dùng thông tin trước mốc, nhóm xét loại hàng mà 5.671 khách cá nhân đủ điều kiện đã mua trong giai đoạn theo dõi (truy vấn V06a, V06b). Vì một khách có thể mua nhiều danh mục, Bảng 15 trình bày cả cách đếm theo từng danh mục (không loại trừ nhau) và cách chia thành hai nhóm loại trừ nhau.

Bảng 15: Tỷ lệ rời bỏ theo loại hàng đã mua trong giai đoạn theo dõi (khách cá nhân)

Nhóm	Số khách	Rời bỏ	Tỷ lệ
<i>Theo danh mục (một khách có thể thuộc nhiều dòng)</i>			
Đã mua xe đạp	5.636	879	15,6%
Đã mua phụ kiện	428	290	67,8%
Đã mua quần áo	166	124	74,7%
<i>Hai nhóm loại trừ nhau</i>			
Chỉ mua xe đạp (chưa mua phụ kiện/quần áo)	5.184	556	10,7%
Có mua phụ kiện hoặc quần áo	487	341	70,0%

Kết quả trái với kỳ vọng ban đầu và trùng lặp nhiều với Bảng 14: trong 314 khách đã mua hai lần trở lên trước mốc có 272 người đã mua phụ kiện hoặc quần áo (V06c). Nói cách khác, “đã mua lần hai” và “đã mua phụ kiện” phần lớn là cùng một nhóm khách, và cả hai đi kèm tỷ lệ rời bỏ cao trong kỳ kiểm tra.

Phát hiện ở Mục 4 rằng phụ kiện là danh mục có nhiều khách mua nhất vẫn đúng, nhưng dữ liệu hiện có không cho phép kết luận việc mua phụ kiện giúp giữ chân khách. Nếu muốn dùng phụ kiện làm công cụ giữ chân, đó phải là một giả thuyết để thử nghiệm




Hình 9: Tỷ lệ rời bỏ theo loại hàng đã mua *trước mốc*, khách cá nhân (V06a, V06b). Ba cột trái không loại trừ nhau; hai cột phải là hai nhóm loại trừ nhau.

(ví dụ so sánh hai nhóm khách được và không được mời mua phụ kiện), chứ không phải kết luận rút ra từ dữ liệu lịch sử.

6.6 Chênh lệch tỷ lệ rời bỏ theo đặc điểm nhân khẩu học

Bảng 16 và Hình 10 tổng hợp tỷ lệ rời bỏ của 5.671 khách cá nhân đủ điều kiện xét theo từng đặc điểm (truy vấn V07a). Mỗi ô ghi tỷ lệ rời bỏ kèm số khách rời bỏ trên tổng số khách của nhóm. Tuổi được tính tại mốc 30/06/2013; các đặc điểm khác lấy từ khảo sát, không có ngày ghi nhận, nên được xem là không đổi trong kỳ.



Hình 10: Tỷ lệ rời bỏ theo thu nhập: nhóm thu nhập trung bình rời bỏ nhiều nhất.

Chênh lệch lớn nhất nằm ở các đặc điểm kinh tế. Khách thu nhập 25-75 nghìn USD, làm lao động kỹ thuật hoặc văn phòng, chưa có nhà và có ít xe hơi có tỷ lệ rời bỏ cao gấp 2-4 lần nhóm thu nhập trên 75 nghìn hoặc làm quản lý. Nhóm thu nhập thấp nhất (dưới 25 nghìn) lại có tỷ lệ rời bỏ thấp (10,2%). Đây là các tương quan quan sát được trong mẫu; dữ liệu không có biến về động cơ mua hay mức nhạy giá của từng khách, nên báo cáo không suy ra nguyên nhân. Mối liên hệ giữa thu nhập, lý do mua “giá cả” và việc rời bỏ là một giả thuyết để kiểm tra bằng phân tích nhiều biến ở giai đoạn sau.

Tuổi, giới tính và tình trạng hôn nhân cho chênh lệch chỉ 0-2 điểm phần trăm giữa các nhóm. Với cỡ mẫu vài nghìn khách mỗi nhóm, chênh lệch nhỏ như vậy chưa cho thấy mối liên hệ đáng kể trong phân tích đơn biến; báo cáo chưa thực hiện kiểm định thống kê nên

Bảng 16: Tỷ lệ rời bỏ theo đặc điểm cá nhân (rời bỏ / tổng số khách của nhóm)

Đặc điểm	Tỷ lệ rời bỏ theo nhóm	Chênh lệch
Thu nhập/năm	Dưới 25k: 10,2% (82/805) – 25–50k: 23,2% (390/1.681) – 50–75k: 20,4% (332/1.624) – 75–100k: 5,9% (55/931) – Trên 100k: 6,0% (38/630)	17 điểm
Nghề nghiệp	Lao động kỹ thuật: 25,9% (339/1.308) – Văn phòng: 16,7% (171/1.027) – Chuyên môn: 13,3% (231/1.743) – Phổ thông: 12,2% (78/641) – Quản lý: 8,2% (78/952)	18 điểm
Số xe hơi	0: 17,5% (274/1.568) – 1: 19,0% (308/1.624) – 2: 15,0% (243/1.616) – 3: 10,4% (52/498) – 4: 5,5% (20/365)	13 điểm
Số con	0: 12,8% (221/1.721) – 1: 21,3% (278/1.305) – 2: 16,1% (204/1.266) – 3: 14,2% (89/628) – 4: 14,6% (71/486) – 5: 12,8% (34/265)	8 điểm
Có nhà riêng	Không: 19,6% (347/1.769) – Có: 14,1% (550/3.902)	6 điểm
Học vấn	Cử nhân: 11,5% (217/1.883) – Cao đẳng dở dang: 17,8% (278/1.558) – Sau đại học: 17,8% (175/985) – Trung học: 18,3% (165/903) – Trung học dở dang: 18,1% (62/342)	7 điểm
Độ tuổi (tại 30/06/2013)	Dưới 40: 14,5% (111/766) – 40–49: 16,4% (355/2.160) – 50–59: 16,6% (284/1.710) – 60+: 14,2% (147/1.035)	2 điểm
Giới tính	Nữ: 15,3% (436/2.855) – Nam: 16,4% (461/2.816)	1 điểm
Hôn nhân	Đã kết hôn: 15,7% (450/2.870) – Độc thân: 16,0% (447/2.801)	0 điểm
Đăng ký email khuyến mãi	Không: 14,9% (462/3.099) – Chỉ AdventureWorks: 17,8% (268/1.506) – Cả đối tác: 15,7% (167/1.066)	3 điểm

không kết luận “không có liên hệ”, chỉ ghi nhận rằng các đặc điểm này không phân biệt được hai nhóm ở mức mô tả. Với email khuyến mãi, dữ liệu chỉ ghi khách có đăng ký hay không (0, 1, 2), không ghi khách thực sự nhận hay mở email nào, nên bảng trên không đánh giá được hiệu quả chương trình email; nó chỉ cho thấy trạng thái đăng ký không đi kèm tỷ lệ ở lại cao hơn.

Xu hướng chung, đặc điểm hành vi (Bảng 14, 15) tạo ra chênh lệch lớn hơn nhiều so với đặc điểm cá nhân, phù hợp với kết quả của Buckinx và Van den Poel (2005) trong bán lẻ không hợp đồng, dù chiều của mối liên hệ ở CompanyX khác với nghiên cứu đó.

6.7 Tổng hợp: dấu hiệu nào đi kèm với việc rời bỏ?

Mỗi dấu hiệu ở đây được xét riêng lẻ, và chúng chồng lên nhau ở nhiều chỗ: hai dấu hiệu đầu gần như là một, thị trường Bắc Mỹ và nhóm đại lý cũng vậy. Tất cả đều là tương quan quan sát được trong mẫu, chưa phải quan hệ nhân quả. Tách xem dấu hiệu nào thực sự có tác động độc lập là việc của phần xây dựng mô hình ở giai đoạn sau, và mọi đặc điểm đưa vào mô hình phải được tính trước mối gắn nhãn như đã làm ở đây.

Bảng 17: Xếp hạng sơ bộ các dấu hiệu theo mức độ phân biệt khách ở lại và khách rời bỏ

#	Dấu hiệu	Bảng chứng	Mức độ
1	Đã mua phụ kiện/quần áo trước móc (cá nhân)	70,0% so với 10,7%	Rất mạnh
2	Đã mua 2 lần trước móc (cá nhân)	57,2% so với 13,4%	Rất mạnh
3	Thị trường	Úc 4% ↔ Canada 42%	Rất mạnh
4	Là đại lý	28,6% so với 15,8%	Mạnh
5	Thu nhập trung bình	6% ↔ 23%	Mạnh
6	Nghề lao động kỹ thuật / văn phòng	8% ↔ 26%	Mạnh
7	Chưa có nhà, ít xe hơi	6% ↔ 19%	Trung bình
8	Tuổi, giới tính, hôn nhân, đăng ký email	Chênh lệch dưới 3 điểm	Không đáng kể

7 Giới hạn của dữ liệu và đầu vào cho giai đoạn tiếp theo

7.1 Dữ liệu có đủ điều kiện để nghiên cứu churn không?

Có, với các điều kiện sau. Kho dữ liệu có lịch sử giao dịch đầy đủ ở cấp đơn và dòng hàng trong 37 tháng, có hồ sơ nhân khẩu học cho toàn bộ khách cá nhân và hồ sơ cửa hàng cho toàn bộ đại lý, các liên kết giữa bảng còn nguyên vẹn, và tỷ lệ bản ghi cần loại dưới 1%. Những yếu tố này đủ để tạo nhãn rời bỏ theo quy ước và tính các đặc trưng hành vi tại một mốc thời gian.

7.2 Những giới hạn cần ghi nhận

- **Không có nhãn rời bỏ thật.** Nhãn 12 tháng là quy ước; 3.486 khách trong dữ liệu từng quay lại sau hơn một năm nghỉ (V13), nên một phần khách gắn nhãn “rời bỏ” có thể chỉ mua thưa.
- **Mất cân đối thời gian.** 73,7% đơn hàng dồn vào 12 tháng cuối (78,4% nếu chỉ xét kênh online); chỉ 6.206 trong 19.119 khách có đủ thời gian quan sát. Kết quả về rời bỏ vì thế phản ánh nhóm khách gia nhập trước giữa 2013, không đại diện cho toàn bộ khách.
- **Chỉ có một kỳ kiểm tra.** Dữ liệu kết thúc ngày 30/06/2014 nên không thể kiểm tra lại với mốc khác hoặc cửa sổ dài hơn.
- **Thiếu biến về động cơ và tương tác.** Không có dữ liệu về khiếu nại, trả hàng, tương tác marketing thực tế, giá của đối thủ; lý do mua chỉ có ở kênh online và do khách tự khai.

- **Dữ liệu mô phỏng.** CompanyX là AdventureWorks; một số quan hệ (ví dụ khách mua hai lần trước mốc rời bỏ nhiều hơn) có thể là đặc điểm của cách sinh dữ liệu chứ không phải hành vi thực.
- **Dữ liệu đã bị can thiệp.** 8 ràng buộc kiểm tra bị tắt và hai cột bị nối thành cho phép rộng để chứa được sáu đơn hồng. Điều này có nghĩa kho dữ liệu nhận được không còn ở trạng thái gốc, nên mọi kiểm tra chất lượng phải dựa vào truy vấn trực tiếp chứ không thể tin vào khai báo ràng buộc của cơ sở dữ liệu.
- **Ba trường không dùng được.** **Status** chỉ có hai trong sáu giá trị mà tài liệu mô tả; **ShipDate** luôn bằng ngày đặt cộng bảy ngày nên không chứa thông tin về chất lượng giao hàng; hạn dùng thẻ tín dụng kết thúc trước ngày đặt ở 30.334 đơn. Không trường nào trong ba trường này dùng được để giải thích việc rời bỏ.
- **Chưa kiểm định thống kê và chưa phân tích nhiều biến.** Mọi chênh lệch trong báo cáo là mô tả đơn biến.

7.3 Đầu vào cho các phần tiếp theo

Từ phân tích này, các phần Problem Statement, mô hình hóa và thiết kế hệ hỗ trợ quyết định có thể dùng: (i) định nghĩa nhân rời bỏ theo mốc 30/06/2013 và kỳ kiểm tra 12 tháng, kèm nguyên tắc mọi đặc trưng phải tính trước mốc; (ii) tập phân tích 6.206 khách (hoặc 6.148 nếu loại đơn hủy và đơn âm) với nhân 16,9% (17,6%); (iii) danh sách bảng và cột nguồn ở Mục 1; (iv) các câu hỏi còn mở: vì sao khách tại Úc có tỷ lệ rời bỏ thấp hơn hẳn các thị trường online tương tự; vì sao khách đã mua hai lần hoặc đã mua phụ kiện trước mốc lại rời bỏ nhiều hơn; đại lý có nên dùng ngưỡng ngắn hơn 12 tháng không; và liệu thu nhập, lý do mua “giá cả” và việc rời bỏ có liên hệ với nhau khi xét đồng thời.

8 Kết luận

Kho dữ liệu CompanyX là bộ AdventureWorks với 72 bảng và 24 view, trong đó khoảng 10 bảng thuộc hai nhóm Sales và Person đủ để mô tả khách hàng và lịch sử mua. Các liên kết giữa bảng còn nguyên vẹn và mọi phép cộng đều khớp, nhưng dữ liệu *không* sạch như vẻ bề ngoài: 8 ràng buộc kiểm tra đang bị tắt, hai cột bị đổi thành cho phép rỗng, và có một vùng hỏng gồm sáu đơn hàng liên tiếp với 75 dòng sản phẩm, mỗi đơn mang đúng một kiểu lỗi, cùng ba dòng hỏng trong bảng khuyến mãi. Tính cả 701 dòng khách không có đơn và 315 đơn hủy thì phần phải loại vẫn dưới 1,1% bản ghi, và quan trọng hơn, việc loại chúng không làm đổi bất kỳ kết luận nào về rời bỏ.


Khách hàng gồm hai nhóm rất khác nhau: 18.484 khách cá nhân mua online, phần lớn chỉ mua một lần với giá trị trung bình 1.755 USD mỗi khách trong 37 tháng; và 635 đại lý đặt hàng gần như mỗi quý, trung bình 142.856 USD mỗi đại lý, chiếm 74% tổng phải trả. Xe đạp chiếm 86% doanh thu trước thuế; phụ kiện chiếm 1% doanh thu nhưng có nhiều khách mua nhất. Ở kênh online, ba phần tư đơn có ghi lý do mua nêu “giá cả”.

Dữ liệu không có nhãn rời bỏ; theo quy ước mốc 30/06/2013 và kỳ kiểm tra 12 tháng, 1.050 trong 6.206 khách đủ điều kiện (16,9%) không mua lại. Tỷ lệ này là 28,6% ở đại lý và 15,8% ở khách cá nhân; chênh nhau tới 10 lần giữa các lãnh thổ (Úc 4,0%, Canada 42,2%). Khi chỉ dùng thông tin trước mốc, khách cá nhân đã mua hai lần hoặc đã mua phụ kiện lại có tỷ lệ rời bỏ cao hơn nhiều so với khách mới mua một chiếc xe (57–70% so với 11–13%); bản nháp đầu đã kết luận ngược lại do tính đặc trưng trên cả kỳ kiểm tra, và sai sót đó đã được sửa. Thu nhập, nghề nghiệp và tài sản cho chênh lệch 13–18 điểm phần trăm; tuổi, giới tính, hôn nhân dưới 2 điểm. Tất cả là tương quan đơn biến trong mẫu.

Dữ liệu đủ điều kiện để bước sang giai đoạn nghiên cứu churn, với các giới hạn về nhãn quy ước, mất cân đối thời gian, thiếu biến động cơ và bản chất mô phỏng của dữ liệu đã nêu ở Mục 7.

Phụ lục A. Môi trường thực thi và cách tái lập kết quả

Toàn bộ số liệu trong báo cáo được sinh lại từ đầu trong một lần chạy duy nhất trên bản khôi phục từ **CompanyX.bak**. Hình 11 mô tả đường đi của dữ liệu, từ tệp sao lưu đến con số in trong báo cáo.



Hình 11: Đường đi của dữ liệu từ tệp sao lưu đến con số in trong báo cáo.

Bảng 18: Môi trường thực thi

Thành phần	Phiên bản / cấu hình
Hệ quản trị CSDL	Microsoft SQL Server 2022 (RTM-CU26) 16.0.4265.3, Developer Edition (64-bit)
Nền tảng	Docker, ảnh <code>mcr.microsoft.com/mssql/server:2022-latest</code> , Ubuntu 22.04.5 LTS
Cổng kết nối	1433
Cơ sở dữ liệu	CompanyX , khôi phục từ CompanyX.bak (tên gốc bên trong: AdventureWorks2022)
Công cụ truy vấn	DBeaver (khám phá) và <code>sqlcmd</code> của <code>mssql-tools18</code> (chạy tự động, chốt số)
Trình biên dịch báo cáo	XeLaTeX (TeX Live), gói <code>pgfplots</code> 1.18 cho biểu đồ

Để kết quả trong Phụ lục B có thể kiểm chứng được, một số truy vấn được in kèm bản chép nguyên văn phiên chạy `sqlcmd`. Trong các khối nền tối, dòng màu sáng ở trên là lệnh đã gõ (mật khẩu được che bằng '***'), phần còn lại là những gì máy chủ in ra, giữ nguyên tên cột, độ rộng cột và dòng tổng kết (**N rows affected**). Khối dưới đây xác nhận danh tính máy chủ, cơ sở dữ liệu và quy mô dữ liệu tại thời điểm chạy.

```
sqlcmd — xác nhận máy chủ và quy mô dữ liệu

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/a_env.sql
phien_ban      an_ban      csdl      thoi_diem_chay
-----
16.0.4265.3    Developer Edition (64-bit)    CompanyX    2026-09-16 03:10:42

(1 rows affected)
don_hang      khach_hang      tong_phai_tra      tu_ngay      den_ngay
-----
31465      19119      123155140.61    2011-05-31    2014-06-30

(1 rows affected)
```

Các lệnh tái lập toàn bộ kết quả

```
# 1. Khởi động SQL Server và nạp tệp sao lưu vào container
docker run -d --name sqlserver -p 1433:1433 \
  -e ACCEPT_EULA=Y -e MSSQL_SA_PASSWORD='<mat_khau>' \
  mcr.microsoft.com/mssql/server:2022-latest
docker cp CompanyX.bak sqlserver:/var/opt/mssql/data/

# 2. Khởi phục cơ sở dữ liệu
SQLCMD="/opt/mssql-tools18/bin/sqlcmd -S localhost -U sa -P $PWD_SA -C"
docker exec sqlserver $SQLCMD -Q "
RESTORE DATABASE CompanyX FROM DISK='/var/opt/mssql/data/CompanyX.bak'
WITH MOVE 'AdventureWorks2022' TO '/var/opt/mssql/data/CompanyX.mdf',
      MOVE 'AdventureWorks2022_log' TO '/var/opt/mssql/data/CompanyX_log.ldf';"

# 3. Chạy bộ truy vấn kiểm chứng và ghi kết quả ra tệp UTF-8
docker cp verify_queries.sql sqlserver:/tmp/
docker exec sqlserver $SQLCMD -f 65001 -h -1 -W -s "|" \
  -i /tmp/verify_queries.sql > verify_results.txt
```

Hai tùy chọn của `sqlcmd` cần lưu ý. `-f 65001` đặt bảng mã UTF-8 cho đầu ra; thiếu nó, các nhãn tiếng Việt trong lệnh `PRINT` bị mất dấu. Đi kèm, mọi chuỗi tiếng Việt trong script phải viết dưới dạng `PRINT N'...'` (chuỗi Unicode), vì chuỗi `varchar` thường sẽ bị chuyển đổi theo bảng mã của collation và mất dấu ngay trước khi ra khỏi máy chủ. `-h -1 -W -s "|"` bỏ tiêu đề cột, cắt khoảng trắng thừa và ngăn cách các cột bằng dấu sổ đứng, cho ra định dạng gọn và dễ đối chiếu.

Ngoài ra, script bắt buộc phải mở đầu bằng `SET QUOTED_IDENTIFIER ON` và `SET ANSI_NULLS ON`. Các truy vấn nhân khẩu học đọc view `Sales.vPersonDemographics`, mà view này gọi phương thức XML trên cột `Person.Demographics`; SQL Server từ chối thực thi nếu hai tùy chọn trên không bật. DBeaver bật sẵn nên script chạy bình thường trong giao diện, còn `sqlcmd` thì không, và sẽ dừng với lỗi `Msg 1934`. Đây là lý do bản đầu của `verify_queries.sql` chỉ chạy được trong DBeaver.

Phụ lục B. Truy vấn kiểm chứng và kết quả thực thi

Phụ lục này in nguyên văn các truy vấn đã dùng để chốt số, kèm kết quả trả về. Mã V trong ngoặc ở phần thân báo cáo trở tới các mục dưới đây. Toàn bộ truy vấn nằm trong tệp `verify_queries.sql`; kết quả thô nằm trong `verify_results.txt`. Để tiết kiệm chỗ, những truy vấn lặp cùng một khuôn mẫu trên nhiều chiều dữ liệu chỉ in một chiều đại diện và ghi chú phần còn lại.

Ba mẫu câu lặp lại xuyên suốt và nên đọc trước:

- **agg** — gom mỗi khách thành một dòng với ngày mua đầu (`MIN(OrderDate)`), dùng để lọc điều kiện đủ thời gian quan sát.
- **pre** — các đơn *trước hoặc bằng* mốc 30/06/2013, nguồn duy nhất cho mọi biến đặc trưng.
- **post** — các khách có đơn trong kỳ kiểm tra 01/07/2013–30/06/2014. Khách không xuất hiện trong **post** được gắn nhãn rời bỏ.

Việc tách **pre** và **post** chính là cơ chế chống rò rỉ dữ liệu đã nêu ở Mục 6.4.

B.1 Kho dữ liệu có gì bên trong — xem trực tiếp bằng `sqlcmd`

Mục này không tính toán gì mới. Mục đích của nó là cho người đọc nhìn thấy dữ liệu thật: kho có những bảng nào, mỗi bảng có cột gì, các bảng nối với nhau ra sao, và một bản ghi cụ thể trông như thế nào. Mọi khối dưới đây là bản chép nguyên văn phiên chạy, không chỉnh sửa. Mười truy vấn dùng ở đây được gom trong tệp đính kèm `tour_queries.sql`, chạy độc lập với `verify_queries.sql`.

1. Kho gồm sáu nhóm bảng

Câu hỏi đầu tiên khi mở một kho dữ liệu lạ là nó được chia thành những phần nào. Truy vấn vào các bảng hệ thống `sys.schemas`, `sys.tables` và `sys.views` cho ngay bức tranh tổng thể.

```
sqlcmd — sáu nhóm bảng và số bảng, số view mỗi nhóm

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t1_schema.sql
nhom          so_bang    so_view
-----
Production    25          3
Sales         19          7
Person        13          2
HumanResources 6           6
Purchasing    5           2
dbo           4           4

(6 rows affected)
```

Kết quả này là căn cứ cho Bảng 3. Nhóm **Production** nhiều bảng nhất (25) nhưng phần lớn phục vụ sản xuất và tồn kho; nhóm **Sales** với 19 bảng mới là nơi chứa dữ liệu cần cho chủ đề rời bỏ.

2. Bảng nào lớn nhất

Số bảng chưa nói lên khối lượng dữ liệu. Cộng số dòng từ `sys.partitions` cho thấy dữ liệu thật sự nằm ở đâu.

```
sqlcmd — 12 bảng nhiều dòng nhất, kèm số cột

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t2_rows.sql
bang                so_dong    so_cot
-----
Sales.SalesOrderDetail    121317    11
Production.TransactionHistory    113530    9
Production.TransactionHistoryArchive    89253    9
Production.WorkOrder    72591    10
Production.WorkOrderRouting    67131    12
Sales.SalesOrderHeader    31465    26
Sales.SalesOrderHeaderSalesReason    27647    3
Person.BusinessEntity    20777    3
Person.PersonPhone    19972    4
Person.EmailAddress    19972    5
Person.Password    19972    5
Person.Person    19972    13

(12 rows affected)
```

Hai bảng đầu của nhóm **Production** (lịch sử giao dịch kho, 113.530 và 89.253 dòng) lớn hơn cả bảng đơn hàng, nhưng chúng ghi việc nhập xuất vật tư nội bộ chứ không phải hành vi mua của khách, nên không được dùng. Bảng thực sự dùng là **SalesOrderDetail** (121.317 dòng) và **SalesOrderHeader** (31.465 dòng, 26 cột).

3. Bảng khách hàng có những cột gì

Sales.Customer là bảng trung tâm của phân tích. Nó chỉ có 7 cột, và ba trong số đó là khóa ngoại — đó là lý do bảng này đóng vai trò cầu nối.

```
sqlcmd — cấu trúc cột của Sales.Customer

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t3_cols.sql
cot      kieu      nullable khoa_ngoai_toi
-----
CustomerID    int      không
PersonID      int      có      Person
StoreID       int      có      Store
TerritoryID   int      có      SalesTerritory
AccountNumber  varchar  không
rowguid       uniqueid không
ModifiedDate  datetime không

(7 rows affected)
```

Điểm đáng chú ý: **PersonID** và **StoreID** đều cho phép rỗng. Chính hai cột này phân biệt khách cá nhân với đại lý, và cũng chính chúng tạo ra ba nhóm bản ghi ở khối tiếp theo.

4. Ba nhóm bản ghi trong cùng một bảng khách hàng

Đây là chi tiết dễ gây nhầm lẫn nhất của kho dữ liệu, nên cần nhìn tận mắt.

```
sqlcmd — ba nhóm bản ghi khác nhau trong Sales.Customer

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
-d CompanyX -i /tmp/t4_cust.sql
CustomerID PersonID StoreID TerritoryID AccountNumber
-----
11000      13531      NULL      9 AW00011000
11001      5454      NULL      9 AW00011001
11002      11269     NULL      9 AW00011002

(3 rows affected)
CustomerID PersonID StoreID TerritoryID AccountNumber
-----
29484      291       292      5 AW00029484
29485      293       294      4 AW00029485
29486      295       296      3 AW00029486

(3 rows affected)
CustomerID PersonID StoreID TerritoryID AccountNumber
-----
1          NULL      934      1 AW00000001
2          NULL      1028     1 AW00000002

(2 rows affected)
```

Nhóm thứ nhất có **PersonID** và **StoreID** rỗng: khách cá nhân mua online (18.484 người). Nhóm thứ hai có cả hai: người liên hệ của một đại lý (635). Nhóm thứ ba có **PersonID** rỗng nhưng **StoreID** có giá trị: 701 bản ghi đại lý không gắn người liên hệ nào, và không bản ghi nào trong nhóm này có đơn hàng. Đó là 701 bản ghi bị loại ở Bảng 9.

5. Các bảng nối với nhau bằng gì

Khai báo khóa ngoại cho biết đường đi hợp lệ giữa các bảng, không phải suy đoán từ tên cột.

```
sqlcmd — khóa ngoại của bốn bảng trung tâm

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
-d CompanyX -i /tmp/t10_fk.sql
bang_con      qua_cot      toi_bang
-----
Customer      PersonID     Person
Customer      StoreID      Store
Customer      TerritoryID  SalesTerritory
SalesOrderDetail ProductID     SpecialOfferProduct
SalesOrderDetail SalesOrderID  SalesOrderHeader
SalesOrderDetail SpecialOfferID SpecialOfferProduct
SalesOrderHeader BillToAddressID Address
SalesOrderHeader CreditCardID   CreditCard
SalesOrderHeader CurrencyRateID CurrencyRate
SalesOrderHeader CustomerID      Customer
SalesOrderHeader SalesPersonID  SalesPerson
SalesOrderHeader ShipMethodID   ShipMethod
SalesOrderHeader ShipToAddressID Address
SalesOrderHeader TerritoryID     SalesTerritory
Store          BusinessEntityID BusinessEntity
Store          SalesPersonID  SalesPerson

(16 rows affected)
```

Đọc từ dưới lên thấy rõ chuỗi nối dùng trong hầu hết truy vấn của báo cáo: **SalesOrderDetail** → **SalesOrderHeader** → **Customer** → **Person** hoặc **Store**. Cũng thấy **SalesOrderHeader** còn nối tới địa chỉ, thẻ tín dụng, tỷ giá và phương thức vận chuyển — những nhánh không dùng cho chủ đề rời bỏ.

6. Một đơn hàng cụ thể trông như thế nào

Quan hệ một đơn – nhiều dòng hàng dễ hiểu nhất khi xem một đơn thật.

```
sqlcmd — đơn 43659: phần đầu đơn và 12 dòng hàng

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t5_order.sql
SalesOrderID OrderDate CustomerID Online Status SubTotal TotalDue
-----
43659 2011-05-31 29825 0 5 20565.62 23153.23

(1 rows affected)
LineID ProductID Qty LineTotal SanPham
-----
1 776 1 2024.99 Mountain-100 Black, 42
2 777 3 6074.98 Mountain-100 Black, 44
3 778 1 2024.99 Mountain-100 Black, 48
4 771 1 2039.99 Mountain-100 Silver, 38
5 772 1 2039.99 Mountain-100 Silver, 42
6 773 2 4079.99 Mountain-100 Silver, 44
7 774 1 2039.99 Mountain-100 Silver, 48
8 714 3 86.52 Long-Sleeve Logo Jersey, M
9 716 1 28.84 Long-Sleeve Logo Jersey, XL
10 709 6 34.20 Mountain Bike Socks, M
11 712 2 10.37 AWC Logo Cap
12 711 4 80.75 Sport-100 Helmet, Blue

(12 rows affected)
```

Đơn 43659 là đơn của một đại lý (**Online** = 0), gồm 12 dòng hàng: 7 dòng xe đạp Mountain-100 các cỡ, còn lại là áo, tất, mũ. Cộng **LineTotal** của 12 dòng được 20.565,6206 USD, đúng bằng **SubTotal** ở phần đầu đơn; từ đó lên 23.153,23 USD là do thuế và phí vận chuyển. Lưu ý cột **LineTotal** ở trên đã được làm tròn tới hai chữ số thập phân cho dễ đọc, nên cộng tay các giá trị hiển thị sẽ ra 20.565,60 — lệch 0,02 USD so với giá trị đầy đủ. Kiểu **money** của SQL Server lưu bốn chữ số thập phân, và chính sai số làm tròn này là lý do truy vấn V01c đặt ngưỡng so sánh 0,01 USD thay vì đòi bằng nhau tuyệt đối.

7. Nhân khẩu học nằm trong một khối XML

Thông tin khảo sát khách hàng không được lưu thành cột mà gói trong một khối XML. Đặc điểm này chi phối mọi truy vấn nhân khẩu học của báo cáo: không thể đọc thẳng từ bảng, phải đi qua view để tách, và vì view gọi phương thức XML nên mỗi phiên chạy đều phải bật **QUOTED_IDENTIFIER**.



```
sqlcmd — khối XML gốc và view tách nó thành cột

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t6_xml.sql
do_dai_xml
-----
604

(1 rows affected)
noi_dung_xml
-----
"><TotalPurchaseYTD>4751.05</TotalPurchaseYTD><DateFirstPurchase>2001-07-22Z</DateFirstPurchase><BirthDate>1966-04-08Z</BirthDate><MaritalStatus>M</MaritalStatus><YearlyIncome>75001-100000</YearlyIncome><Gender>M</Gender><TotalChildren>2</TotalChildren><NumberChildrenAtHome>0</NumberChildrenAtHome><Education>Bachelors </Education><Occupation>Professional</Occupation><HomeOwnerFlag>1</HomeOwnerFlag><NumberCarsOwned>0</NumberCarsOwned><CommuteDistance>1-2 Miles</CommuteDistance></IndividualSurvey>

(7 rows affected)
GioiTinh NgaySinh HonNhan ThuNhap NgheNghiep SoCon SoXe
-----
M 1966-04-08 M 75001-100000 Professional 2 0

(1 rows affected)
```

Khối XML dài 604 ký tự chứa toàn bộ kết quả khảo sát của một người. Muốn dùng được, phải tách nó ra, và CompanyX đã làm sẵn việc đó bằng view **Sales.vPersonDemographics** — kết quả là phần cuối khối trên, cùng một người, đã thành các cột truy vấn được. Vì view gọi phương thức XML nên mọi truy vấn chạm tới nó đều cần **SET QUOTED_IDENTIFIER ON** — dòng này nằm ở đầu tệp truy vấn nên không hiện trong khối trên, vì **sqlcmd** chỉ in kết quả chứ không in lại câu lệnh đầu vào.

8. Mười lãnh thổ bán hàng

```
sqlcmd — toàn bộ bảng Sales.SalesTerritory

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t7_terr.sql
ID      LanhTho      Ma      KhuVuc      DoanhSoNam
-----
1 Northwest    US      North America  7887186.79
2 Northeast    US      North America  2402176.85
3 Central      US      North America  3072175.12
4 Southwest    US      North America  10510853.87
5 Southeast    US      North America  2538667.25
6 Canada       CA      North America  6771829.14
7 France       FR      Europe         4772398.31
8 Germany      DE      Europe         3805202.35
9 Australia    AU      Pacific        5977814.92
10 United Kingdom GB      Europe         5012905.37

(10 rows affected)
```

Bảng chỉ có 10 dòng nhưng quyết định cách chia thị trường trong suốt báo cáo: năm vùng của Mỹ, cộng Canada, ba nước châu Âu và Úc, gộp thành ba khu vực.

9. Cây phân loại sản phẩm

```
sqlcmd — bốn danh mục lớn, số danh mục con và khoảng giá

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t8_cat.sql
DanhMucLon  SoDanhMucCon  SoSanPham  GiaThapNhat  GiaCaoNhat
-----
Components          14          134         20.24       1431.50
Bikes                 3           97         539.99       3578.27
Clothing              8           35           8.99         89.99
Accessories          12           29           2.29        159.00

(4 rows affected)
```

Bảng này giải thích nghịch lý ở Mục 4: xe đạp chỉ có 97 sản phẩm nhưng giá từ 540 đến 3.578 USD, trong khi phụ kiện có 29 sản phẩm giá từ 2,29 đến 159 USD. Ít mã hàng và giá cao là lý do xe đạp chiếm 86% doanh thu dù ít khách mua hơn phụ kiện.

10. Lý do mua là quan hệ nhiều-nhiều

```
sqlcmd — bảng lý do mua và ví dụ đơn có ba lý do

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t9_reason.sql
ID          LyDo          Nhom
-----
1 Price      Other
2 On Promotion  Promotion
3 Magazine Advertisement  Marketing
4 Television Advertisement  Marketing
5 Manufacturer Other
6 Review     Other
7 Demo Event Marketing
8 Sponsorship Marketing
9 Quality    Other
10 Other     Other

(10 rows affected)
DonHang     LyDo
-----
51214 On Promotion
51214 Other
51214 Price
51298 On Promotion
51298 Other
51298 Price

(6 rows affected)
```

Bảng gốc chỉ có 10 lý do. Khối thứ hai cho thấy vì sao không được cộng gộp: đơn 51214 và 51298 mỗi đơn gán ba lý do, nên khi nối bảng đơn hàng với bảng cầu thì một đơn bị nhân thành ba dòng. Đó là lý do Bảng 13 đếm riêng số đơn thay vì số dòng.

11. Vùng dữ liệu hỏng

Mười khối trên cho thấy kho dữ liệu được tổ chức tốt. Khối này cho thấy mặt còn lại. Bắt đầu từ chính khai báo của cơ sở dữ liệu: trong 89 ràng buộc kiểm tra, có 8 ràng buộc đang bị tắt.

```
sqlcmd — tám ràng buộc CHECK đang bị tắt

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t11_check.sql
bang          rang_buoc          dieu_kien
-----
SalesOrderDetail  CK_SalesOrderDetail_OrderQty  ([OrderQty]>(0))
SalesOrderDetail  CK_SalesOrderDetail_UnitPrice  ([UnitPrice]>=(0.00))
SalesOrderHeader  CK_SalesOrderHeader_DueDate    ([DueDate]>=[OrderDate])
SalesOrderHeader  CK_SalesOrderHeader_ShipDate   ([ShipDate]>=[OrderDate])
SalesOrderHeader  CK_SalesOrderHeader_SubTotal   ([SubTotal]>=(0.00))
SpecialOffer      CK_SpecialOffer_DiscountPct    ([DiscountPct]>=(0.00))
SpecialOffer      CK_SpecialOffer_EndDate        ([EndDate]>=[StartDate])
SpecialOffer      CK_SpecialOffer_MaxQty         ([MaxQty]>=(0))

(8 rows affected)
```

Mỗi dòng ở đây là một điều kiện mà cơ sở dữ liệu *lẽ ra* phải bảo đảm nhưng hiện không còn bảo đảm nữa. Danh sách này đóng vai trò như một bản đồ: nó chỉ ra chính xác nên đi tìm dữ liệu sai ở đâu. Lần theo hai ràng buộc đầu tiên thì thấy vùng hỏng.

```
sqlcmd — sáu đơn hỏng, mỗi đơn một kiểu lỗi

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/t12_broken.sql
don          so_dong_hong kieu_hong          loi_ngay
-----
43677        12 UnitPrice = 0
43678        19 UnitPrice am
43679        3 UnitPrice = NULL
43680        15 OrderQty = NULL   ShipDate truoc OrderDate
43681        21 OrderQty = 0    ShipDate truoc OrderDate
43682        5 OrderQty am

(6 rows affected)
```

Sáu đơn liên tiếp, 75 dòng sản phẩm, và mỗi đơn mang đúng một kiểu lỗi khác nhau: đơn giá bằng 0, âm, rỗng; số lượng rỗng, bằng 0, âm. Một lỗi nhập liệu ngẫu nhiên không bao giờ sắp xếp ngăn nắp như vậy. Hai đơn 43680 và 43681 còn có ngày giao nằm trước ngày đặt gần một năm, ứng với hai ràng buộc **DueDate** và **ShipDate** cũng đang bị tắt.

Vùng hỏng này không bị các phép kiểm tra cộng trừ bắt được: truy vấn V01c trả về 0 đơn sai và phép cộng **TotalDue** khớp trên cả 31.465 đơn, vì dữ liệu hỏng được đưa vào một cách nhất quán về số học. Mục 1 phân tích cơ chế này qua đơn 43677.

Vùng hỏng thứ hai nằm ở bảng chương trình khuyến mãi.



```
sqlcmd — ba dòng hồng trong bảng khuyến mãi

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
-d CompanyX -i /tmp/t13_offer.sql
ID      mo_ta      bat_dau      ket_thuc      sl_min      sl_max
-----
3 Volume Discount 15 to 24 2011-05-31 2014-05-30      15      -24
15 Half-Price Pedal Sale 2013-07-14 2012-08-14      0      NULL
16 Mountain-500 Silver Clea 2014-03-31 2013-05-30      0      NULL

(3 rows affected)
```

Chương trình 3 tên là “Volume Discount 15 to 24” nhưng số lượng tối đa ghi -24. Chương trình 15 và 16 có ngày kết thúc nằm trước ngày bắt đầu. Riêng chương trình 16 kéo theo hậu quả sang dữ liệu bán hàng: 169 dòng hàng của mẫu xe Mountain-500 Silver, trị giá 25.899 USD ở kênh đại lý, được áp mức giảm 40% vào thời điểm mà theo đúng bảng này, chương trình còn chưa bắt đầu.

Bài học rút ra cho phần sau: khi nhận một kho dữ liệu, nên đọc trạng thái ràng buộc trước khi đọc dữ liệu. Ràng buộc bị tắt là chỉ dấu rõ và nhanh hơn nhiều so với việc dò tìm bất thường bằng thống kê mô tả, và trong trường hợp này nó dẫn thẳng tới toàn bộ vùng hồng.

B.2 V01 — Doanh thu và tính nhất quán giữa hai cấp dữ liệu

Mục đích: xác nhận tổng doanh thu, và kiểm tra bảng đơn hàng có khớp với bảng dòng hàng hay không.

```
1  -- V01a: thanh phần doanh thu cấp đơn
2  SELECT COUNT(*) AS orders,
3         CAST(SUM(SubTotal) AS decimal(18,2)) AS subtotal,
4         CAST(SUM(TaxAmt) AS decimal(18,2)) AS tax,
5         CAST(SUM(Freight) AS decimal(18,2)) AS freight,
6         CAST(SUM(TotalDue) AS decimal(18,2)) AS totaldue
7  FROM Sales.SalesOrderHeader;
8
9  -- V01c: so đơn có SubTotal khác tổng LineTotal (phai bằng 0)
10 SELECT COUNT(*) AS mismatched_orders FROM (
11     SELECT h.SalesOrderID
12     FROM Sales.SalesOrderHeader h
13     JOIN Sales.SalesOrderDetail d ON d.SalesOrderID = h.SalesOrderID
14     GROUP BY h.SalesOrderID, h.SubTotal
15     HAVING ABS(h.SubTotal - SUM(d.LineTotal)) > 0.01) x;
```

Kết quả

Chỉ tiêu	Số đơn	Trước thuế	Thuế	Tổng phải trả
V01a — cấp đơn	31.465	109.784.735,90	10.186.974,46	123.155.140,61
V01b — cấp dòng hàng	121.317 dòng	109.784.735,89	—	—
V01c — đơn lệch > 0,01 USD	0			

Hai cấp dữ liệu lệch nhau đúng 0,01 USD trên tổng 109,8 triệu, là sai số làm tròn của kiểu **money**, và không có đơn nào lệch quá một xu. Phí vận chuyển 3.183.430,25 USD cộng nốt vào để ra 123.155.140,61 USD.



V01d — doanh thu và độ phủ khách theo danh mục

Danh mục	Số khách	Số lượng	Doanh thu dòng hàng (USD)
Bikes (Xe đạp)	9.719	90.221	94.597.297,06
Components (Linh kiện)	580	49.032	11.796.253,20
Clothing (Quần áo)	7.327	73.651	2.119.738,53
Accessories (Phụ kiện)	15.461	61.920	1.271.447,10
Dòng không có danh mục	0		

Không dòng hàng nào thiếu danh mục, nên phép cộng theo danh mục phủ đúng 100% doanh thu. Đây là căn cứ cho Hình 3.

B.3 V02 — Chất lượng dữ liệu

```

1  -- V02b: đơn có tổng tiền âm
2  SELECT SalesOrderID, CustomerID, OrderDate, Status, OnlineOrderFlag,
3         CAST(TotalDue AS decimal(18,2)) AS totaldue,
4         (SELECT COUNT(*) FROM Sales.SalesOrderDetail d
5          WHERE d.SalesOrderID = h.SalesOrderID) AS n_lines
6  FROM Sales.SalesOrderHeader h WHERE TotalDue < 0 OR SubTotal < 0;
7
8  -- V02c: ba nhóm bán ghi trong Sales.Customer
9  SELECT grp, COUNT(*) AS customers, SUM(has_order) AS with_orders FROM (
10     SELECT CASE WHEN PersonID IS NULL THEN 'PersonID NULL'
11              WHEN StoreID IS NULL THEN 'Individual'
12              ELSE 'Store contact' END AS grp,
13            CASE WHEN EXISTS (SELECT 1 FROM Sales.SalesOrderHeader h
14                             WHERE h.CustomerID = c.CustomerID) THEN 1 ELSE 0 END AS has_order
15     FROM Sales.Customer c) x GROUP BY grp;
16
17  -- V02d: kiểm tra trùng khóa và tính toán ven khóa ngoại
18  SELECT (SELECT COUNT(*) - COUNT(DISTINCT CustomerID) FROM Sales.Customer) AS dup_customer
19         ,
20         (SELECT COUNT(*) - COUNT(DISTINCT SalesOrderID) FROM Sales.SalesOrderHeader) AS dup_order,
21         (SELECT COUNT(*) - COUNT(DISTINCT SalesOrderDetailID) FROM Sales.SalesOrderDetail) AS dup_line,
22         (SELECT COUNT(*) FROM sys.foreign_keys) AS fk_count,
23         (SELECT COUNT(*) FROM sys.foreign_keys WHERE is_not_trusted=1) AS fk_untrusted;

```

Kết quả

Mã	Nội dung kiểm tra	Kết quả
V02a	Đơn trạng thái 5 (đã giao)	31.150 đơn / 121.978.690,44 USD
V02a	Đơn trạng thái 6 (đã hủy)	315 đơn / 1.176.450,17 USD
V02b	Đơn 43678 (31/05/2011, đại lý, trạng thái 5)	−8.563,45 USD, 19 dòng
V02b	Đơn 43682 (31/05/2011, đại lý, trạng thái 5)	−3.387,74 USD, 5 dòng
V02c	Khách cá nhân (có đơn)	18.484 / 18.484
V02c	Liên hệ của đại lý (có đơn)	635 / 635
V02c	PersonID rỗng (có đơn)	701 / 0
V02d	Trùng khóa chính: CustomerID / SalesOrderID	0 / 0
V02d	Trùng khóa chính: SalesOrderDetailID	0
V02d	Khóa ngoại: tổng số / số không đáng tin	90 / 0



Cả 90 khóa ngoại đều ở trạng thái đáng tin (`is_not_trusted = 0`), nghĩa là SQL Server đã kiểm chứng toàn bộ dữ liệu hiện có thỏa mãn ràng buộc, chứ không chỉ khai báo suông. Đây là căn cứ cho khẳng định “toàn bộ 90 mối liên kết còn nguyên vẹn” ở Mục 1.

V02e — quy mô trước và sau khi lọc

Tập	Khách	Đơn	Dòng hàng	Tổng phải trả (USD)
Trước lọc	19.119	31.465	121.317	123.155.140,61
Sau lọc (bỏ 315 đơn hủy và 6 đơn hỏng)	18.995	31.144	120.072	121.986.324,02
Chênh lệch	-124	-321	-1.245	-1.168.816,59 (0,95%)

B.4 V03 — Kênh bán và mức tập trung doanh thu

```

1  -- V03: hai nhóm khách hàng
2  SELECT CASE WHEN c.StoreID IS NULL THEN 'Individual' ELSE 'Store' END AS ctype,
3          COUNT(DISTINCT h.CustomerID) AS customers, COUNT(*) AS orders,
4          CAST(SUM(h.TotalDue) AS decimal(18,2)) AS totaldue,
5          CAST(AVG(h.TotalDue) AS decimal(18,2)) AS avg_per_order,
6          CAST(SUM(h.TotalDue)/COUNT(DISTINCT h.CustomerID) AS decimal(18,2)) AS avg_per_customer,
7          CAST(COUNT(*)*1.0/COUNT(DISTINCT h.CustomerID) AS decimal(10,2)) AS orders_per_customer
8  FROM Sales.SalesOrderHeader h
9  JOIN Sales.Customer c ON c.CustomerID = h.CustomerID
10 GROUP BY CASE WHEN c.StoreID IS NULL THEN 'Individual' ELSE 'Store' END;
11
12 -- V03c: Pareto - chia khách thành 5 phần bằng nhau theo tổng chi tiêu
13 WITH s AS (SELECT CustomerID, SUM(TotalDue) AS spend
14            FROM Sales.SalesOrderHeader GROUP BY CustomerID),
15      r AS (SELECT spend, NTILE(5) OVER (ORDER BY spend DESC) AS q FROM s)
16 SELECT q, COUNT(*) AS customers, CAST(SUM(spend) AS decimal(18,2)) AS revenue,
17        CAST(100.0*SUM(spend)/(SELECT SUM(spend) FROM s) AS decimal(5,1)) AS pct
18 FROM r GROUP BY q ORDER BY q;

```

Kết quả V03

Nhóm	Khách	Đơn	Doanh thu (USD)	TB/đơn	TB/khách	Đơn/khách
Cá nhân	18.484	27.659	32.441.339,12	1.172,90	1.755,10	1,50
Đại lý	635	3.806	90.713.801,49	23.834,42	142.856,38	5,99

Kết quả V03c — ngũ phân vị theo chi tiêu

Nhóm	Số khách	Doanh thu (USD)	Tỷ trọng
1 (chi nhiều nhất)	3.824	110.529.926,50	89,7%
2	3.824	10.110.245,12	8,2%
3	3.824	2.138.622,53	1,7%
4	3.824	280.984,88	0,2%
5 (chi ít nhất)	3.823	95.361,58	0,1%

V03b xác nhận `OnlineOrderFlag` trùng khít với loại khách: toàn bộ 27.659 đơn của khách cá nhân đều có cờ online bằng 1, toàn bộ 3.806 đơn của đại lý đều bằng 0. Vì vậy báo cáo dùng hai cách gọi “kênh online” và “khách cá nhân” thay thế nhau được.



B.5 V04 — Gắn nhãn rời bỏ

Đây là nhóm truy vấn quan trọng nhất của báo cáo. V04a trả lời câu hỏi kho dữ liệu có sẵn nhãn hay không; V04b định nghĩa nhãn chính thức; V04c–V04e là các phương án thay thế dùng để đối chiếu.

```

1  -- V04a: tìm cột nhãn churn có sẵn trong toàn bộ CSDL
2  SELECT OBJECT_SCHEMA_NAME(c.object_id) + '.' + OBJECT_NAME(c.object_id) AS tbl, c.name
3  FROM sys.columns c WHERE c.name LIKE '%churn%' OR c.name LIKE '%active%';
4
5  -- V04b: NHAN CHINH THUC
6  -- Du dieu kien : don dau tien <= 2013-06-30 (co it nhat 12 thang de the hien)
7  -- Churn      : khong co don nao trong 2013-07-01 .. 2014-06-30
8  WITH agg AS (SELECT CustomerID, MIN(OrderDate) AS first_dt
9                FROM Sales.SalesOrderHeader GROUP BY CustomerID),
10 post AS (SELECT DISTINCT CustomerID FROM Sales.SalesOrderHeader
11           WHERE OrderDate >= '2013-07-01' AND OrderDate <= '2014-06-30')
12 SELECT COUNT(*) AS eligible,
13        SUM(CASE WHEN post.CustomerID IS NULL THEN 1 ELSE 0 END) AS churn,
14        SUM(CASE WHEN post.CustomerID IS NOT NULL THEN 1 ELSE 0 END) AS active
15 FROM agg LEFT JOIN post ON post.CustomerID = agg.CustomerID
16 WHERE agg.first_dt <= '2013-06-30';
17
18 -- V04e: cach dem nguoc tu ngay cuoi du lieu (KHONG co dieu kien du thoi gian)
19 WITH lastord AS (SELECT CustomerID, MAX(OrderDate) AS last_dt
20                  FROM Sales.SalesOrderHeader GROUP BY CustomerID)
21 SELECT SUM(CASE WHEN DATEDIFF(day,last_dt,'2014-06-30') > 180 THEN 1 ELSE 0 END) AS silent_6m,
22        SUM(CASE WHEN DATEDIFF(day,last_dt,'2014-06-30') > 365 THEN 1 ELSE 0 END) AS silent_12m,
23        COUNT(*) AS total
24 FROM lastord;

```

Kết quả — so sánh các cách gắn nhãn

Mã	Cách gắn nhãn	Mẫu số	Rời bỏ	Tỷ lệ
V04b	Chính thức: mốc 30/06/2013, kỳ kiểm tra 12 tháng	6.206	1.050	16,9%
V04c	Như trên, chỉ tính đơn trạng thái 5 và không âm	6.148	1.080	17,6%
V04d	Mốc 31/12/2013, kỳ kiểm tra 6 tháng	13.097	8.765	66,9%
V04e	Im lặng > 6 tháng tính từ 30/06/2014, không lọc mẫu	19.119	8.765	45,8%
V04e	Im lặng > 12 tháng tính từ 30/06/2014, không lọc mẫu	19.119	1.016	5,3%

```

sqlcmd — V04b, nhãn rời bỏ chính thức

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/b_v04b.sql
du_dieu_kien roi_bo      o_lai      ty_le
-----
6206      1050      5156      16.9

(1 rows affected)

```

V04a chỉ tìm thấy một cột duy nhất khớp mẫu tên, là **Purchasing.Vendor.ActiveFlag** — cột trạng thái của nhà cung cấp, không liên quan đến khách hàng. Kho dữ liệu vì vậy không có nhãn rời bỏ sẵn, đúng như Mục 6.1 đã nêu.

Ba dòng cuối bảng cho thấy vì sao phải có điều kiện đủ thời gian quan sát. Hai dòng V04e dùng chung mẫu số 19.119 khách, trong đó hàng nghìn người mới mua lần đầu vài tháng trước khi dữ liệu kết thúc; đổi ngưỡng từ 6 lên 12 tháng làm tỷ lệ rơi từ 45,8% xuống 5,3%, một biên độ cho thấy con số phụ thuộc vào ngưỡng nhiều hơn là vào hành vi khách hàng.

V04f — rời bỏ theo lãnh thổ và loại khách (nhãn V04b)

Lãnh thổ	Rời bỏ	Tổng	Tỷ lệ	Lãnh thổ	Rời bỏ	Tổng	Tỷ lệ
Canada	191	453	42,2%	France	86	542	15,9%
Southeast	27	71	38,0%	Germany	60	553	10,8%
Central	22	59	37,3%	United Kingdom	56	628	8,9%
Northwest	210	774	27,1%	Australia	78	1.933	4,0%
Southwest	308	1.148	26,8%	<i>Đại lý</i>	<i>153</i>	<i>535</i>	<i>28,6%</i>
Northeast	12	45	26,7%	<i>Cá nhân</i>	<i>897</i>	<i>5.671</i>	<i>15,8%</i>

V04g — mô tả hồi cứu hai nhóm nhãn

Nhãn	Số khách	Số đơn TB	Số ngày từ đơn đầu đến đơn cuối
Ở lại	5.156	2,62	547,1
Rời bỏ	1.050	1,61	104,2

Hai cột bên phải tính trên *toàn bộ* lịch sử mua, kể cả kỳ kiểm tra, nên chúng chứa sẵn kết quả cần dự báo. Chúng chỉ dùng để mô tả hai nhóm sau khi đã biết nhãn, tuyệt đối không được đưa vào mô hình dự báo.

B.6 V05 — Số lần mua trước mốc

Đây là truy vấn đã sửa lỗi rò rỉ dữ liệu mô tả ở Mục 6.4. Điểm mấu chốt nằm ở mệnh đề WHERE OrderDate <= '2013-06-30' trong CTE pre: số lần mua chỉ được đếm trong giai đoạn theo dõi, tách hẳn khỏi kỳ kiểm tra dùng để gán nhãn.

```

1  -- V05a: số lần mua TRƯỚC MỐC x nhãn rời bỏ (không rò rỉ)
2  WITH pre AS (
3    SELECT h.CustomerID, COUNT(*) AS n_pre,
4           CASE WHEN c.StoreID IS NULL THEN 'Individual' ELSE 'Store' END AS ctype
5    FROM Sales.SalesOrderHeader h
6    JOIN Sales.Customer c ON c.CustomerID = h.CustomerID
7    WHERE OrderDate <= '2013-06-30' -- <-- chỉ giai đoạn theo dõi
8    GROUP BY h.CustomerID, CASE WHEN c.StoreID IS NULL THEN 'Individual' ELSE 'Store' END),
9    post AS (
10     SELECT DISTINCT CustomerID FROM Sales.SalesOrderHeader
11     WHERE OrderDate >= '2013-07-01' AND OrderDate <= '2014-06-30')
12  SELECT ctype,
13         CASE WHEN n_pre = 1 THEN '1' WHEN n_pre = 2 THEN '2'
14              WHEN n_pre <= 5 THEN '3-5' ELSE '6+' END AS bucket,
15         SUM(CASE WHEN post.CustomerID IS NULL THEN 1 ELSE 0 END) AS churn,
16         COUNT(*) AS total
17  FROM pre LEFT JOIN post ON post.CustomerID = pre.CustomerID
18  GROUP BY ctype, CASE WHEN n_pre = 1 THEN '1' WHEN n_pre = 2 THEN '2'
19                WHEN n_pre <= 5 THEN '3-5' ELSE '6+' END
20  ORDER BY ctype, bucket;

```



```

21
22 -- V05b: CÁCH TÍNH CU, BI RÒ RI - đếm số lần mua trên TOÀN BỘ dữ liệu.
23 --      Giữ lại để đối chiếu, KHÔNG dùng cho kết luận.
24 WITH agg AS (SELECT CustomerID, MIN(OrderDate) AS first_dt, COUNT(*) AS n
25               FROM Sales.SalesOrderHeader GROUP BY CustomerID),
26      post AS (SELECT DISTINCT CustomerID FROM Sales.SalesOrderHeader
27               WHERE OrderDate >= '2013-07-01' AND OrderDate <= '2014-06-30')
28 SELECT CASE WHEN n = 1 THEN '1' WHEN n = 2 THEN '2'
29            WHEN n <= 5 THEN '3-5' ELSE '6+' END AS bucket,
30            SUM(CASE WHEN post.CustomerID IS NULL THEN 1 ELSE 0 END) AS churn, COUNT(*) AS total
31 FROM agg LEFT JOIN post ON post.CustomerID = agg.CustomerID
32 WHERE first_dt <= '2013-06-30'
33 GROUP BY CASE WHEN n = 1 THEN '1' WHEN n = 2 THEN '2'
34            WHEN n <= 5 THEN '3-5' ELSE '6+' END ORDER BY bucket;

```

Kết quả V05a (đúng) so với V05b (rò rỉ)

Nhóm	Số lần	V05a — đếm trước mốc			V05b — đếm toàn bộ		
		Rời bỏ	Tổng	Tỷ lệ	Rời bỏ	Tổng	Tỷ lệ
Cá nhân	1	719	5.357	13,4%			
Cá nhân	2	178	311	57,2%	740	740	100%
Cá nhân	3-5	0	3	0,0%	191	4.004	4,8%
Đại lý	1-2	34	147	23,1%	91	1.160	7,8%
Đại lý	3-5	91	266	34,2%			
Đại lý	6+	28	122	23,0%	28	302	9,3%

Ghi chú: hai khối cột chia nhóm theo cách khác nhau nên không xếp thẳng hàng từng dòng; bảng chỉ nhằm cho thấy độ lệch về chiều hướng. Ở V05b, mọi khách có đúng một đơn trong toàn bộ dữ liệu đều tất yếu bị gắn nhãn rời bỏ ($740/740 = 100\%$), vì nếu họ có mua trong kỳ kiểm tra thì số đơn đã không thể bằng 1. Đó chính là biểu hiện của rò rỉ: biến đặc trưng đã chứa sẵn câu trả lời.

```

sqlcmd — V05a, số lần mua trước mốc

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
  -d CompanyX -i /tmp/c_v05a.sql
loai    so_lan roi_bo    tong
-----
Ca nhan 1          719    5357
Ca nhan 2          178    311
Ca nhan 3-5         0      3
Dai ly 1           21    121
Dai ly 2           13     26
Dai ly 3-5         91    266
Dai ly 6+          28    122

(7 rows affected)

```

V05c — theo nhóm khách gia nhập (khách cá nhân)

Năm mua lần đầu	Mua 1 lần trước mốc				Mua 2 lần trở lên		
	Rời bỏ	Tổng	Tỷ lệ		Rời bỏ	Tổng	Tỷ lệ
2011	204	1.071	19,0%		53	130	40,8%
2012	176	2.622	6,7%		85	121	70,2%
Nửa đầu 2013	339	1.664	20,4%		40	63	63,5%

B.7 V06 — Danh mục sản phẩm đã mua trước mốc

```

1  -- V06b: hai nhóm loại trừ nhau, khách cá nhân du điều kiện
2  WITH pre AS (
3      SELECT DISTINCT h.CustomerID FROM Sales.SalesOrderHeader h
4      JOIN Sales.Customer c ON c.CustomerID = h.CustomerID
5      WHERE OrderDate <= '2013-06-30' AND c.StoreID IS NULL),
6      post AS (
7      SELECT DISTINCT CustomerID FROM Sales.SalesOrderHeader
8      WHERE OrderDate >= '2013-07-01' AND OrderDate <= '2014-06-30'),
9      cat AS (
10     SELECT h.CustomerID,
11            MAX(CASE WHEN pc.Name IN ('Accessories','Clothing') THEN 1 ELSE 0 END) AS has_acc
12     FROM Sales.SalesOrderDetail d
13     JOIN Sales.SalesOrderHeader h ON h.SalesOrderID = d.SalesOrderID
14     JOIN Production.Product p ON p.ProductID = d.ProductID
15     JOIN Production.ProductSubcategory ps ON ps.ProductSubcategoryID = p.ProductSubcategoryID
16     JOIN Production.ProductCategory pc ON pc.ProductCategoryID = ps.ProductCategoryID
17     WHERE h.OrderDate <= '2013-06-30' -- <-- lại là giải đoạn theo dõi
18     GROUP BY h.CustomerID)
19 SELECT CASE WHEN has_acc = 1 THEN 'Co phụ kiện/quan áo'
20            ELSE 'Chi xe đạp hoặc linh kiện' END AS grp,
21        SUM(CASE WHEN post.CustomerID IS NULL THEN 1 ELSE 0 END) AS churn, COUNT(*) AS total
22 FROM pre JOIN cat ON cat.CustomerID = pre.CustomerID
23 LEFT JOIN post ON post.CustomerID = pre.CustomerID
24 GROUP BY has_acc;

```

Kết quả V06a, V06b, V06c

Nhóm khách cá nhân đủ điều kiện	Rời bỏ	Tổng	Tỷ lệ
<i>V06a — theo danh mục, một khách có thể thuộc nhiều dòng</i>			
Đã mua xe đạp trước mốc	879	5.636	15,6%
Đã mua phụ kiện trước mốc	290	428	67,8%
Đã mua quần áo trước mốc	124	166	74,7%
<i>V06b — hai nhóm loại trừ nhau</i>			
Chỉ mua xe đạp hoặc linh kiện	556	5.184	10,7%
Có mua phụ kiện hoặc quần áo	341	487	70,0%

V06c — mức trùng lặp giữa hai dấu hiệu (số khách)

Số lần mua trước mốc	Không mua phụ kiện	Có mua phụ kiện	Tổng
1 lần	5.142	215	5.357
2 lần trở lên	42	272	314
Tổng	5.184	487	5.671

Bảng này giải thích vì sao hai dấu hiệu xếp hạng 1 và 2 ở Bảng 17 không độc lập: trong 314 khách mua từ hai lần trở lên trước mốc thì 272 người (87%) cũng đã mua phụ kiện hoặc quần áo. Hai cột của Bảng 15 và Bảng 14 vì vậy mô tả gần như cùng một nhóm khách.

B.8 V07 — Nhân khẩu học và tỷ lệ rời bỏ

Truy vấn gốc ghép 10 chiều nhân khẩu học bằng UNION ALL. Dưới đây in một chiều đại diện; chín chiều còn lại (nghề nghiệp, số xe, số con, sở hữu nhà, học vấn, tuổi, giới tính, hôn nhân, đăng ký email) lặp lại đúng khuôn mẫu này, chỉ thay biểu thức gộp nhóm.

```
1 WITH agg AS (SELECT CustomerID, MIN(OrderDate) AS first_dt
2               FROM Sales.SalesOrderHeader GROUP BY CustomerID),
3 post AS (SELECT DISTINCT CustomerID FROM Sales.SalesOrderHeader
4           WHERE OrderDate >= '2013-07-01' AND OrderDate <= '2014-06-30'),
5 lab AS (
6   SELECT c.PersonID, CASE WHEN post.CustomerID IS NULL THEN 1 ELSE 0 END AS churn
7   FROM agg
8   JOIN Sales.Customer c ON c.CustomerID = agg.CustomerID
9   LEFT JOIN post ON post.CustomerID = agg.CustomerID
10  WHERE first_dt <= '2013-06-30' AND c.StoreID IS NULL) -- chỉ khách cá nhân
11 SELECT 'Income' AS dim, d.YearlyIncome AS val,
12        SUM(churn) AS churn, COUNT(*) AS total,
13        CAST(100.0*SUM(churn)/COUNT(*) AS decimal(5,1)) AS pct
14 FROM lab JOIN Sales.vPersonDemographics d ON d.BusinessEntityID = lab.PersonID
15 GROUP BY d.YearlyIncome
16 -- UNION ALL ... lặp lại cho Occupation, Cars, Children, HomeOwner,
17 -- Education, Age, Gender, Marital, EmailPromotion
18 ORDER BY dim, val;
```

Kết quả đầy đủ V07a (5.671 khách cá nhân đủ điều kiện)

Chiều	Giá trị	Rời bỏ	Tổng	Tỷ lệ
Thu nhập	0–25.000	82	805	10,2%
Thu nhập	25.001–50.000	390	1.681	23,2%
Thu nhập	50.001–75.000	332	1.624	20,4%
Thu nhập	75.001–100.000	55	931	5,9%
Thu nhập	trên 100.000	38	630	6,0%
Nghề nghiệp	Skilled Manual	339	1.308	25,9%
Nghề nghiệp	Clerical	171	1.027	16,7%
Nghề nghiệp	Professional	231	1.743	13,3%
Nghề nghiệp	Manual	78	641	12,2%
Nghề nghiệp	Management	78	952	8,2%
Số xe hơi	0	274	1.568	17,5%
Số xe hơi	1	308	1.624	19,0%
Số xe hơi	2	243	1.616	15,0%
Số xe hơi	3	52	498	10,4%

(tiếp trang sau)



Chiều	Giá trị	Rời bỏ	Tổng	Tỷ lệ
Số xe hơi	4	20	365	5,5%
Số con	0	221	1.721	12,8%
Số con	1	278	1.305	21,3%
Số con	2	204	1.266	16,1%
Số con	3	89	628	14,2%
Số con	4	71	486	14,6%
Số con	5	34	265	12,8%
Sở hữu nhà	Không	347	1.769	19,6%
Sở hữu nhà	Có	550	3.902	14,1%
Học vấn	Partial High School	62	342	18,1%
Học vấn	High School	165	903	18,3%
Học vấn	Partial College	278	1.558	17,8%
Học vấn	Bachelors	217	1.883	11,5%
Học vấn	Graduate Degree	175	985	17,8%
Tuổi tại 30/06/2013	dưới 40	111	766	14,5%
Tuổi tại 30/06/2013	40–49	355	2.160	16,4%
Tuổi tại 30/06/2013	50–59	284	1.710	16,6%
Tuổi tại 30/06/2013	60+	147	1.035	14,2%
Giới tính	Nữ	436	2.855	15,3%
Giới tính	Nam	461	2.816	16,4%
Hôn nhân	Đã kết hôn	450	2.870	15,7%
Hôn nhân	Độc thân	447	2.801	16,0%
Đăng ký email	0 — không đăng ký	462	3.099	14,9%
Đăng ký email	1 — chỉ AdventureWorks	268	1.506	17,8%
Đăng ký email	2 — cả đối tác	167	1.066	15,7%

Mỗi chiều cộng lại đúng 5.671 khách, xác nhận không có khách nào bị mất hoặc đếm trùng khi ghép các nhánh UNION ALL.

B.9 V08–V09 — Lý do mua, khuyến mãi và phân bổ thời gian

```

1  -- V08b: lý do mua theo kênh. Dem riêng so don, so don va so khach vi day la
2  --      quan hệ nhiều-nhiều: một đơn có thể gán nhiều lý do.
3  SELECT r.Name, r.ReasonType, h.OnlineOrderFlag,
4         COUNT(*) AS reason_rows,
5         COUNT(DISTINCT hr.SalesOrderID) AS orders,
6         COUNT(DISTINCT h.CustomerID) AS customers
7  FROM Sales.SalesOrderHeaderSalesReason hr
8  JOIN Sales.SalesReason r ON r.SalesReasonID = hr.SalesReasonID

```

```

9 JOIN Sales.SalesOrderHeader h ON h.SalesOrderID = hr.SalesOrderID
10 GROUP BY r.Name, r.ReasonType, h.OnlineOrderFlag
11 ORDER BY h.OnlineOrderFlag, reason_rows DESC;
12
13 -- V09a: đơn theo quý, tách hai kênh
14 SELECT YEAR(OrderDate) AS yr, DATEPART(QUARTER, OrderDate) AS q,
15        SUM(CASE WHEN OnlineOrderFlag = 1 THEN 1 ELSE 0 END) AS online_orders,
16        SUM(CASE WHEN OnlineOrderFlag = 0 THEN 1 ELSE 0 END) AS reseller_orders,
17        COUNT(*) AS all_orders
18 FROM Sales.SalesOrderHeader GROUP BY YEAR(OrderDate), DATEPART(QUARTER, OrderDate)
19 ORDER BY yr, q;

```

Kết quả V09a — đơn theo quý

Quý	Online	Đại lý	Tổng	Quý	Online	Đại lý	Tổng
2011 Q2	146	36	182	2013 Q1	852	314	1.166
2011 Q3	463	175	638	2013 Q2	1.192	383	1.575
2011 Q4	592	193	785	2013 Q3	4.866	454	5.320
2012 Q1	594	265	859	2013 Q4	5.674	447	6.121
2012 Q2	673	281	954	2014 Q1	5.847	449	6.296
2012 Q3	705	317	1.022	2014 Q2	5.284	181	5.465
2012 Q4	771	311	1.082				

Bảng này là căn cứ cho Hình 5. Cột “Đại lý” dao động quanh 450 đơn mỗi quý từ quý 3/2013, nên bước nhảy của cột tổng hoàn toàn đến từ kênh online.

Kết quả V08c — dòng hàng theo loại khuyến mãi

Kênh	Không giảm giá	Có giảm giá	Tỷ lệ có giảm giá
Online	58.247	2.151	3,6%
Đại lý	57.637	3.282	5,4%
Tổng	115.884	5.433	4,5%

B.10 V10–V12 — Cấu trúc kho, nhịp mua và số đơn mỗi khách

```

1 -- V11: khoảng cách giữa hai lần mua liên tiếp của cùng một khách.
2 -- LAG lấy ngày đặt của đơn liên trước trong cùng một CustomerID.
3 WITH o AS (
4     SELECT CustomerID, OrderDate,
5            LAG(OrderDate) OVER (PARTITION BY CustomerID
6                                ORDER BY OrderDate, SalesOrderID) AS prev
7     FROM Sales.SalesOrderHeader WHERE OnlineOrderFlag = 1)
8 SELECT COUNT(*) AS gaps,
9        SUM(CASE WHEN DATEDIFF(day, prev, OrderDate) > 365 THEN 1 ELSE 0 END) AS gaps_over_365,
10       CAST(AVG(DATEDIFF(day, prev, OrderDate)*1.0) AS decimal(8,1)) AS avg_gap,
11       COUNT(DISTINCT CustomerID) AS customers_with_gap
12 FROM o WHERE prev IS NOT NULL;

```

Kết quả

Mã	Chỉ tiêu	Giá trị
V10a	Số bảng / số view	72 / 24
V10a	Khóa chính của bảng cầu lý do mua (SalesOrderID, SalesReasonID)	
V11	Khoảng cách TB giữa hai lần mua — khách cá nhân	317,1 ngày
V11	Số lần quay lại sau hơn 365 ngày — cá nhân	3.472 / 9.175 (37,8%)
V11	Khoảng cách TB giữa hai lần mua — đại lý	98,7 ngày
V12	Khách mua 1 lần	11.649 (60,9%)
V12	Khách mua 2 lần	5.473 (28,6%)
V12	Khách mua 3 lần	1.204 (6,3%)
V12	Khách mua 4–5 lần	456 (2,4%)
V12	Khách mua 6–12 lần	302 (1,6%)
V12	Khách mua 13–28 lần	35 (0,2%)

Khóa chính ghép của `Sales.SalesOrderHeaderSalesReason` xác nhận quan hệ nhiều–nhiều đã nêu ở Mục 1: một đơn có thể gắn nhiều lý do, nên mọi thống kê về lý do mua phải đếm riêng số dòng, số đơn và số khách thay vì cộng gộp.

B.11 V13–V16 — Truy vấn bổ sung của lần rà soát này

Bốn truy vấn dưới đây được thêm vào trong quá trình rà soát lại báo cáo, nhằm truy nguyên những con số trước đó chưa có mã truy vấn kèm theo hoặc chưa khớp với kho dữ liệu.

```

1  -- V14: số khách CÓ ĐƠN theo lãnh thổ.
2  --      Phép JOIN (thay vì LEFT JOIN) tu động loại 701 ban ghi khách không có đơn,
3  --      cho ra mau số 19.119 đúng như phần còn lại của báo cáo.
4  SELECT t.Name AS territory,
5         COUNT(DISTINCT c.CustomerID) AS customers_with_orders,
6         COUNT(h.SalesOrderID)      AS orders,
7         CAST(SUM(h.TotalDue) AS decimal(18,0)) AS revenue
8  FROM Sales.SalesTerritory t
9  JOIN Sales.Customer c      ON c.TerritoryID = t.TerritoryID
10 JOIN Sales.SalesOrderHeader h ON h.CustomerID = c.CustomerID
11 GROUP BY t.Name ORDER BY customers_with_orders DESC;
```

Kết quả V14 — khách, đơn và doanh thu theo lãnh thổ



Lãnh thổ	Khách có đơn	Số đơn	Doanh thu (USD)
Southwest	4.565	6.224	27.119.597
Australia	3.625	6.843	11.814.376
Northwest	3.428	4.594	18.061.660
United Kingdom	1.951	3.219	8.574.049
France	1.844	2.672	8.119.749
Germany	1.812	2.623	5.479.820
Canada	1.677	4.067	18.389.820
Southeast	91	486	8.870.312
Central	69	385	8.913.299
Northeast	57	352	7.812.458
Tổng	19.119	31.465	123.155.140

```
sqlcmd — V14, khách có đơn theo lãnh thổ

$ docker exec sqlserver sqlcmd -S localhost -U sa -P '***' -C -f 65001 \
-d CompanyX -i /tmp/d_v14.sql
lanh_tho      khach_co_don don_hang
-----
Southwest      4565      6224
Australia      3625      6843
Northwest      3428      4594
United Kingdom 1951      3219
France         1844      2672
Germany        1812      2623
Canada         1677      4067
Southeast      91        486
Central        69        385
Northeast      57        352

(10 rows affected)
```

Bảng này cho thấy rõ sự lệch pha giữa số khách và doanh thu đã nêu ở Mục 3: Ưc đúng thứ hai về số khách nhưng chỉ thứ tư về doanh thu, trong khi Canada đứng thứ bảy về số khách lại đứng thứ hai về doanh thu. Ba vùng Southeast, Central và Northeast cộng lại chỉ có 217 khách nhưng mang về 25,6 triệu USD, vì gần như toàn bộ là đại lý.

Kết quả V13, V15, V16

Mã	Chỉ tiêu	Giá trị
V13	Khách từng quay lại sau khoảng nghỉ hơn 365 ngày	3.486
V15	Tỷ lệ đơn nằm trong 12 tháng cuối — tất cả	73,7% (23.202/31.465)
V15	Tỷ lệ đơn nằm trong 12 tháng cuối — chỉ online	78,4%
V16	Khách cá nhân có ít nhất 1 xe hơi	14.246 / 18.484 = 77,1%
V16	Khách cá nhân có nhà riêng	12.502 / 18.484 = 67,6%
V16	Khách cá nhân có con	13.319 / 18.484 = 72,1%

Tài liệu

- [1] Microsoft. *AdventureWorks sample databases*. <https://learn.microsoft.com/en-us/sql/samples/adventureworks-install-configure>, truy cập ngày 15/09/2026.
- [2] Hughes, A. M. (1994). *Strategic Database Marketing*. Probus Publishing, Chicago.
- [3] Fader, P. S., Hardie, B. G. S. & Lee, K. L. (2005). “Counting your customers” the easy way: An alternative to the Pareto/NBD model. *Marketing Science*, 24(2), 275–284.
- [4] Reinartz, W. J. & Kumar, V. (2000). On the profitability of long-life customers in a noncontractual setting: An empirical investigation and implications for marketing. *Journal of Marketing*, 64(4), 17–35.
- [5] Reichheld, F. F. & Sasser, W. E. (1990). Zero defections: Quality comes to services. *Harvard Business Review*, 68(5), 105–111.
- [6] Buckinx, W. & Van den Poel, D. (2005). Customer base analysis: Partial defection of behaviourally loyal clients in a non-contractual FMCG retail setting. *European Journal of Operational Research*, 164(1), 252–268.